

Fahrerassistenzsysteme im Kraftfahrzeug

Prof. Dr.-Ing. Markus Lienkamp



Vorlesungsübersicht

01 Einführung 28.04.2022 – Prof. Lienkamp	01 Einführung 28.04.2022 – Prof. Lienkamp	01 Übung Einführung 28.04.2022 – Hoffmann
02 Sensorik / Wahrnehmung I 05.05.2022 – Prof. Lienkamp	02 Sensorik / Wahrnehmung I 05.05.2022 – Prof. Lienkamp	02 Sensorik / Wahrnehmung I 05.05.2022 – Prof. Lienkamp
03 Sensorik / Wahrnehmung II 12.05.2022 – Dr.-Ing. Diermeyer	03 Sensorik / Wahrnehmung II 12.05.2022 – Dr.-Ing. Diermeyer	03 Übung Sensorik / Wahrnehmung II 12.05.2022 – Schimpe
04 Sensorik / Wahrnehmung III 19.05.2022 – Schimpe	04 Sensorik / Wahrnehmung III 19.05.2022 – Schimpe	04 Übung Sensorik / Wahrnehmung III 19.05.2022 – Schimpe
05 Funktionslogik / Regelung 02.06.2022 – Dr.-Ing. Winkler	05 Funktionslogik / Regelung 02.06.2022 – Dr.-Ing. Winkler	05 Funktionslogik / Regelung 02.06.2022 – Dr.-Ing. Winkler
06 Übung Funktionslogik / Regelung 09.06.2022 – Dr.-Ing. Winkler	06 Funktionale Systemarchitektur 09.06.2022 – Prof. Lienkamp	06 Aktorik 09.06.2022 – Prof. Lienkamp
07 Deep Learning 23.06.2022 – Majstorovic	07 Deep Learning 23.06.2022 – Majstorovic	07 Übung Deep Learning 23.06.2022 – Majstorovic
08 MMI 30.06.2022 – Prof. Bengler	08 MMI 30.06.2022 – Prof. Bengler	08 MMI Übung 30.06.2022 – Prof. Bengler
09 Controllability 07.07.2022 – Prof. Bengler	09 Controllability 07.07.2022 – Prof. Bengler	09 Übung Controllability 07.07.2022 – Winkle
10 Entwicklungsprozess 14.07.2022 – Dr.-Ing. Diermeyer	10 Entwicklungsprozess 14.07.2022 – Dr.-Ing. Diermeyer	10 Übung Entwicklungsprozess 14.07.2022 – Hoffmann
11 Analyse und Bewertung FAS 21.07.2022 – Dr.-Ing. Feig	11 Analyse und Bewertung FAS 21.07.2022 – Dr.-Ing. Feig	11 Übung Analyse und Bewertung FAS 21.07.2022 – Dr.-Ing. Feig
12 Aktuelle und künftige Systeme 28.07.2022 – Prof. Lienkamp	12 Aktuelle und künftige Systeme 28.07.2022 – Prof. Lienkamp	12 Aktuelle und künftige Systeme 28.07.2022 – Prof. Lienkamp

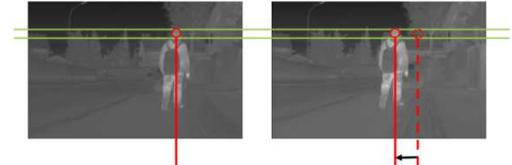
Leitfragen

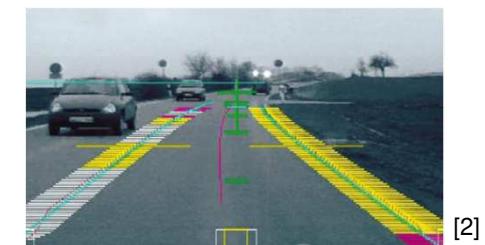
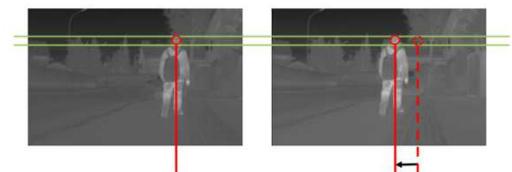
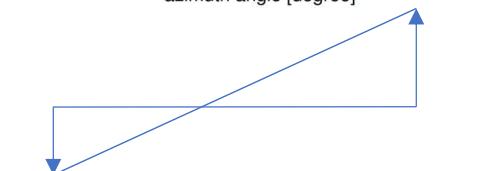
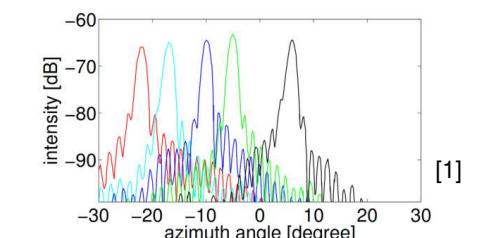
03 – Sensorik/Wahrnehmung II

- 模式识别的程序是什么，如何应用？
- 简单照相机模型如何工作？
- 立体摄影如何工作？

- 不同的边缘检测方法是如何工作的？
- 有哪些分类方法？

- Wie ist das Vorgehen bei der Mustererkennung, und wie kann es angewendet werden?
- Wie funktioniert ein einfaches Kameramodell?
- Wie funktioniert Stereoskopie?

- Wie funktionieren verschiedene Verfahren zur Kantendetektion und wie können sie angewendet werden?

- Welche Ansätze zur Klassifikation gibt es?



Sensorik / Wahrnehmung II

Dr.-Ing. Frank Diermeyer

(Andreas Schimpe, M.Sc.)

Agenda

3 Sensorik / Wahrnehmung II

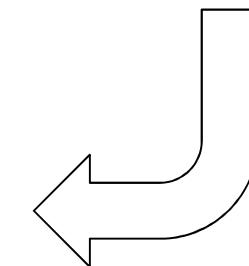
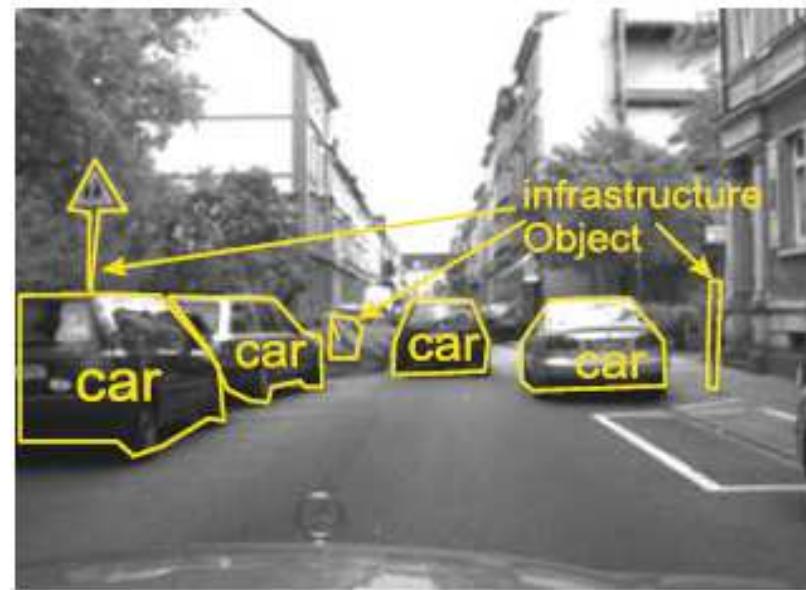
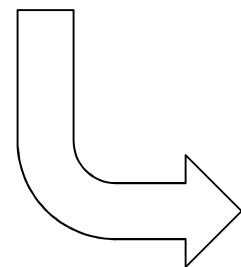
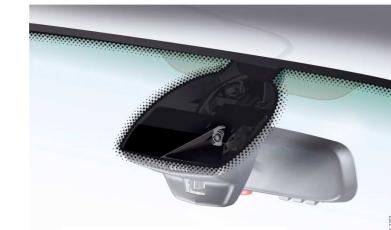
3.1 Detektion mit LiDAR und RADAR

3.2 Maschinelles Sehen

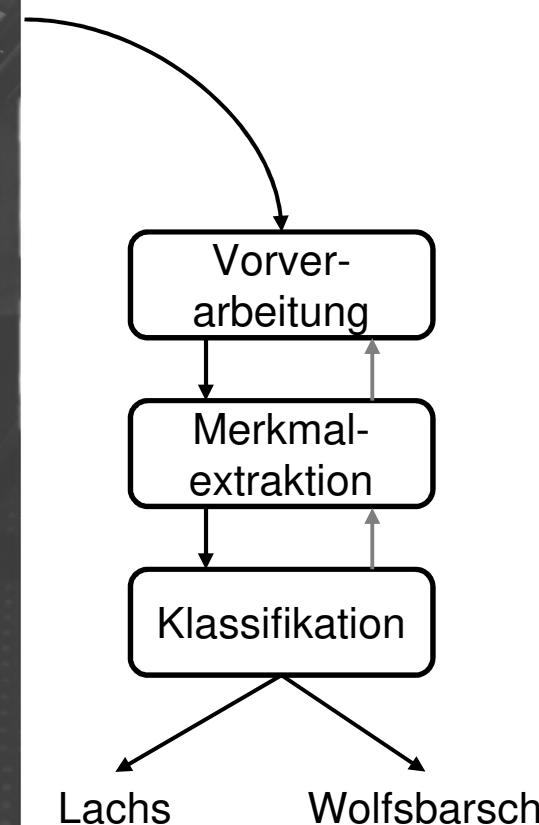


Sensorik/Wahrnehmung II

Wahrnehmungsverfahren



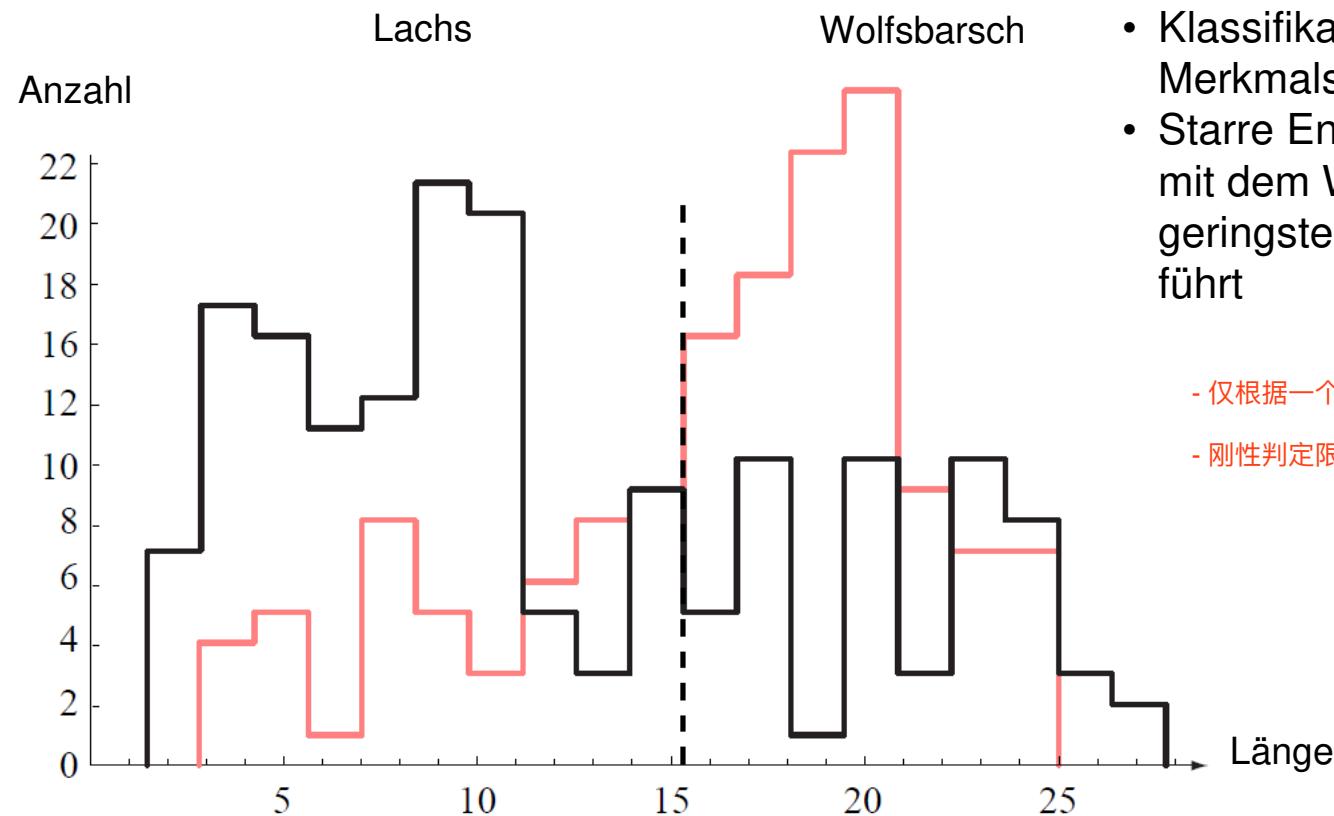
Beispiel für eine Mustererkennungsaufgabe



[Duda 2012]

Klassifikation

Bedeutung von Merkmalextraktion und Klassifikation



- Klassifikation anhand nur eines Merkmals (hier: Länge)
- Starre Entscheidungsgrenze I^* mit dem Wert, der zur geringsten Anzahl an Fehlern führt

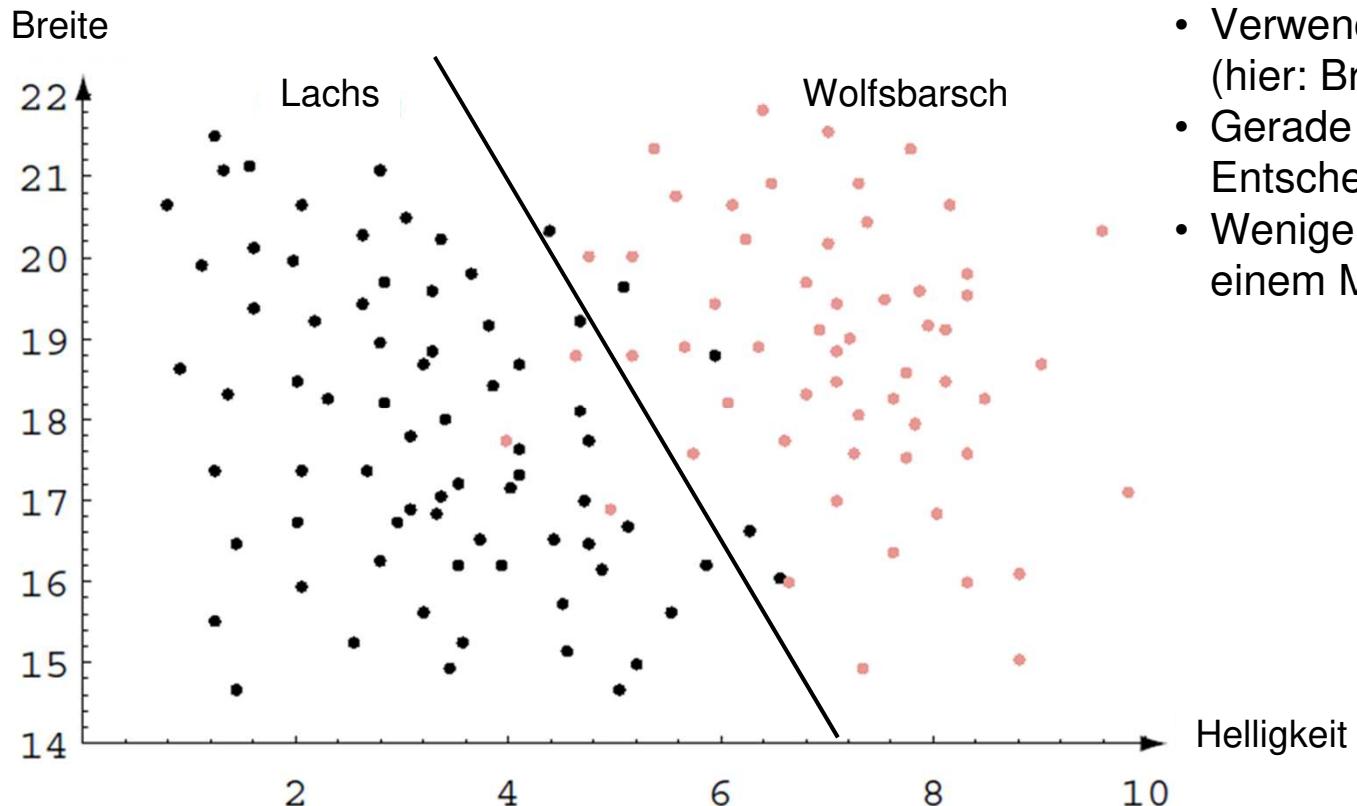
- 仅根据一个特征（此处：长度）进行分类

- 刚性判定限 I^* , 取误差最小的值

[Duda 2012]

Klassifikation

Bedeutung von Merkmalextraktion und Klassifikation

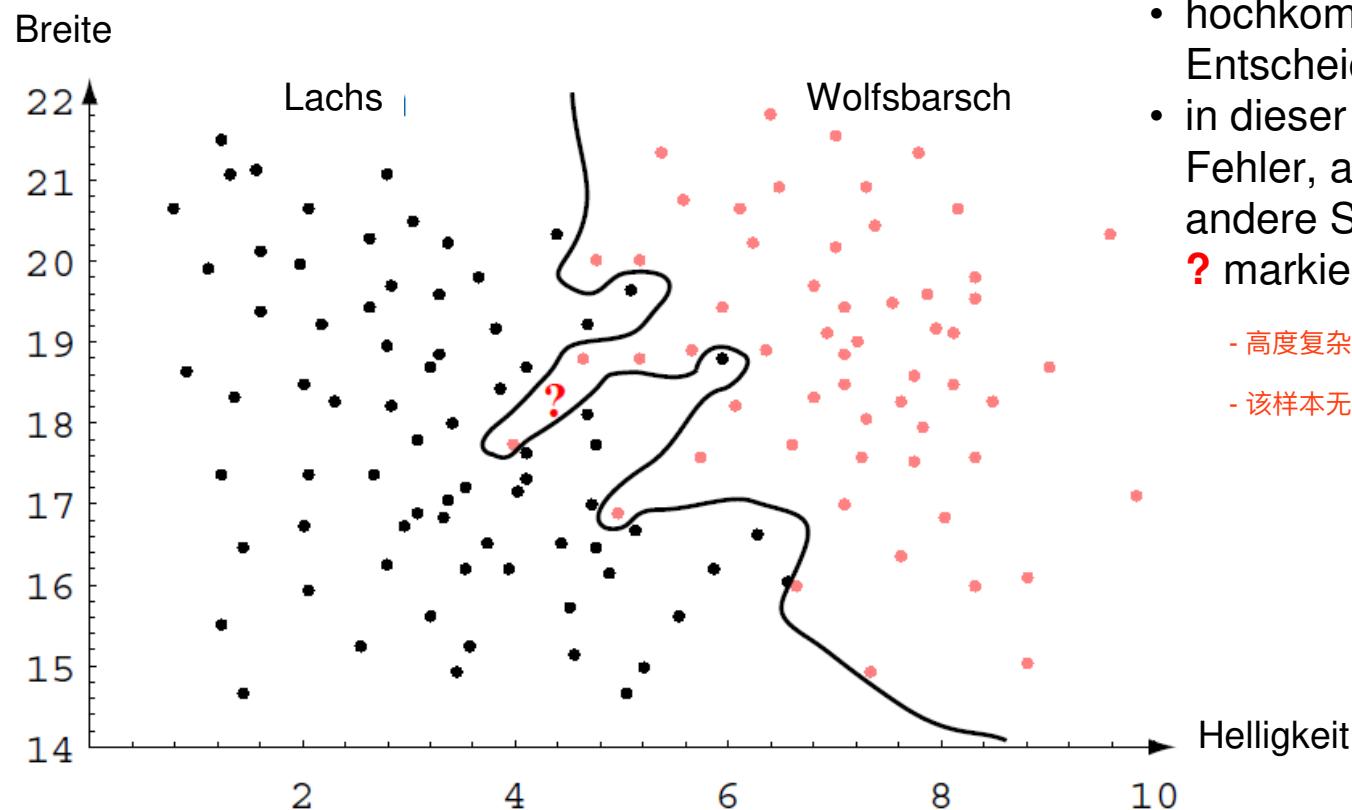


- Verwendung zweier Merkmale (hier: Breite und Helligkeit)
- Gerade → sehr einfache Entscheidungsgrenze I*
- Weniger Fehler als bei nur einem Merkmal

[Duda 2012]

Klassifikation

Bedeutung von Merkmalsextraktion und Klassifikation



- hochkomplexe Entscheidungsgrenze I*
- in dieser Stichprobe keine Fehler, aber unzuverlässig für andere Stichproben (siehe mit ? markierter Punkt)

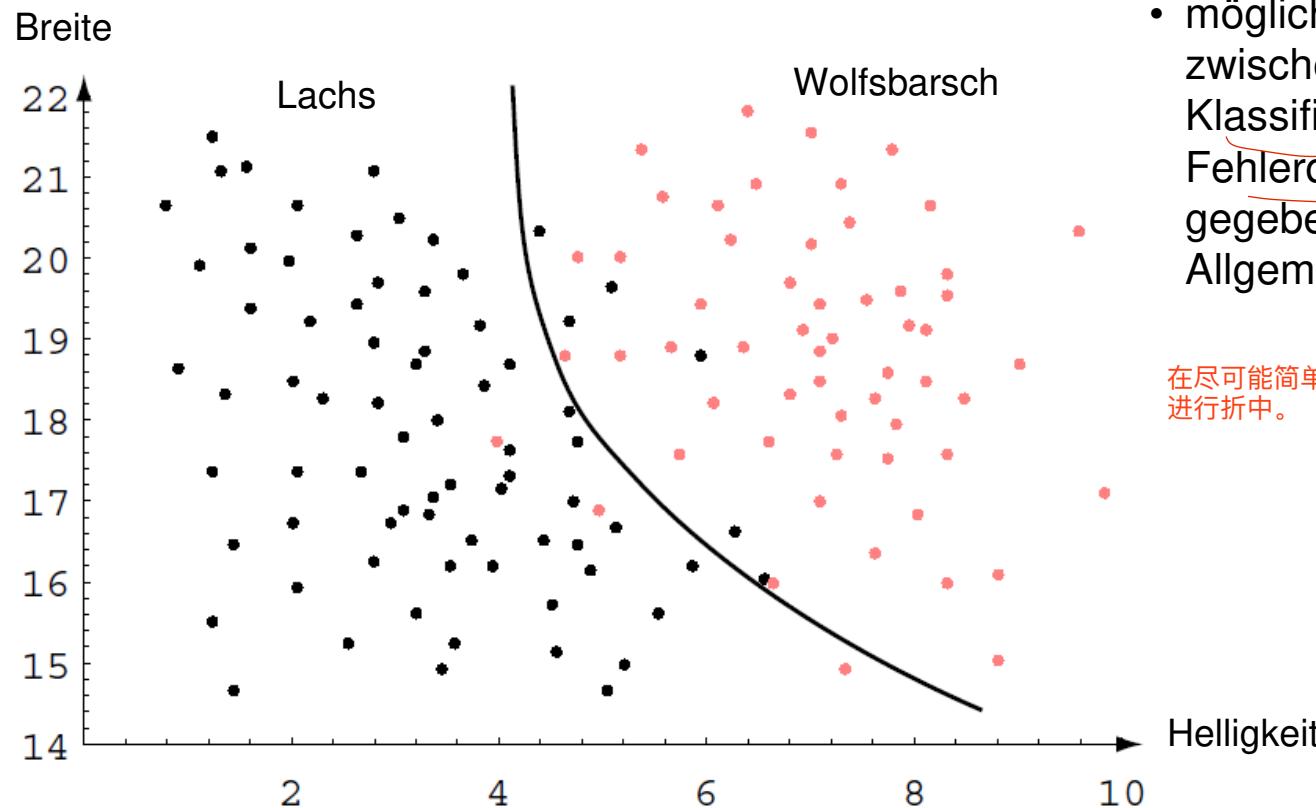
- 高度复杂的决策边界 I*

- 该样本无误，但其他样本不可靠（见标有?）

[Duda 2012]

Klassifikation

Bedeutung von Merkmalsextraktion und Klassifikation



- möglicher Kompromiss zwischen möglichst einfachem Klassifikator, geringer Fehlerquote bei der gegebenen Stichprobe und Allgemeingültigkeit

在尽可能简单的分类器、给定样本的低错误率和普遍有效性之间进行折中。

[Duda 2012]

Histogramm für das Merkmal „Länge“ der beiden (Fisch-)Kategorien: Es gibt keinen Grenzwert I^* (Entscheidungsgrenze) für dieses Merkmal, anhand dessen die beiden Kategorien eindeutig unterscheidbar sind, die Nutzung der Länge allein wird also zu einigen Fehlklassifizierungen führen. Der eingezeichnete Wert I^* ergibt durchschnittlich die wenigsten Fehler.

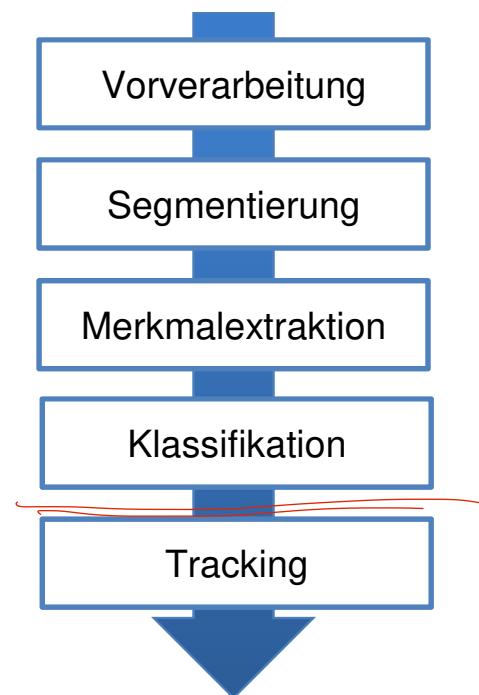
Zwei Merkmale „Breite“ und „Helligkeit“ für Wolfsbarsch (sea bass) und Lachs: Die eingezeichnete Gerade könnte als Entscheidungsgrenze unseres Klassifikators dienen.

Insgesamt liegt die Fehlerrate niedriger als bei der Nutzung nur eines Merkmals wie beim ersten Beispiel, es wird jedoch nach wie vor zu einigen Fehlklassifizierungen kommen.

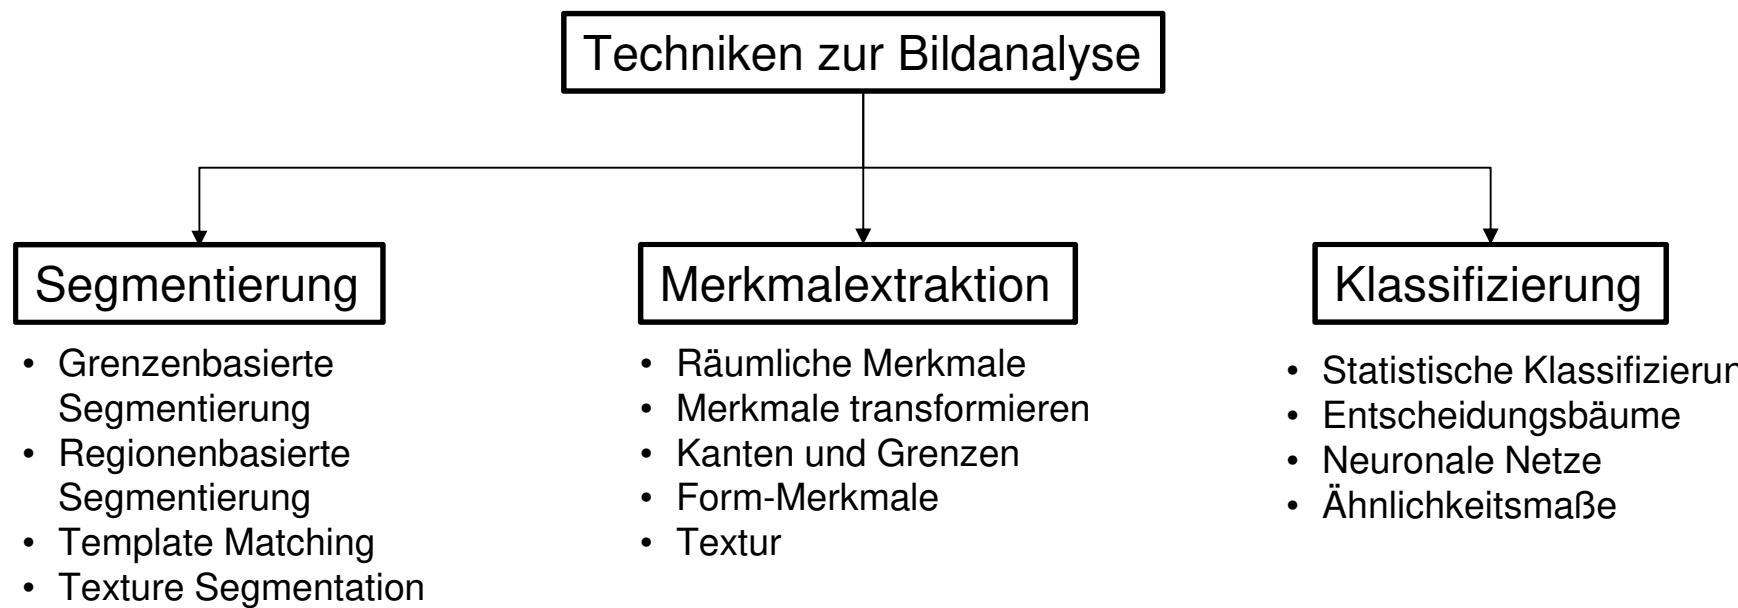
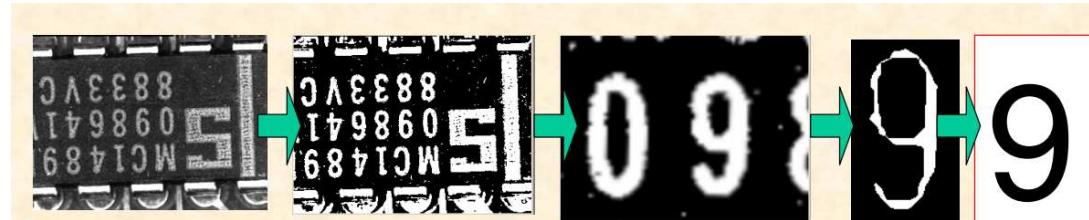
Übermäßig komplexe Modellierungen der Fischarten, wie im dritten Bild, führen zu komplizierten Entscheidungsgrenzen. So können zwar alle Fische unserer Stichprobe fehlerfrei ihrer Art zugeordnet werden, die Ergebnisse bei anderen Stichproben werden aber schlecht sein. Bei dem fiktiven, mit einem roten Fragezeichen markierten Punkt handelt es sich offensichtlich mit hoher Wahrscheinlichkeit um einen Lachs; mit der eingezeichneten komplexen Entscheidungsgrenze wird dieses Exemplar aber als Wolfsbarsch fehlklassifiziert.

Die zuletzt eingezeichnete Entscheidungsgrenze könnte einen optimalen Kompromiss darstellen zwischen einem möglichst einfachen Klassifikator und Performance an der zum Anlernen verwendeten Stichprobe.

Mustererkennungsschritte



Mustererkennungsverfahren



Sensorik / Wahrnehmung II

Dr.-Ing. Frank Diermeyer

(Andreas Schimpe, M.Sc.)

Agenda

3 Sensorik / Wahrnehmung II

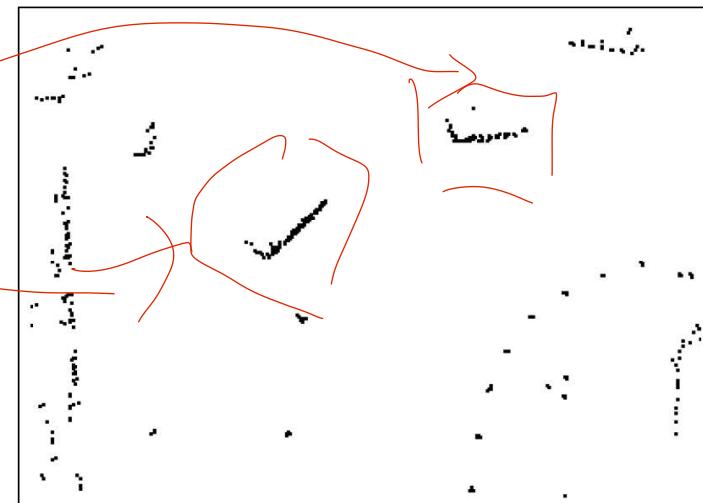
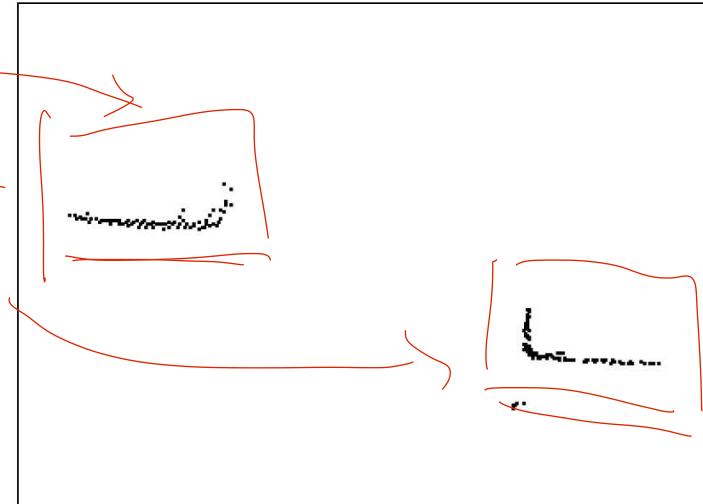
3.1 Detektion mit LiDAR und RADAR

3.2 Maschinelles Sehen



Rohdaten LiDAR – Sick

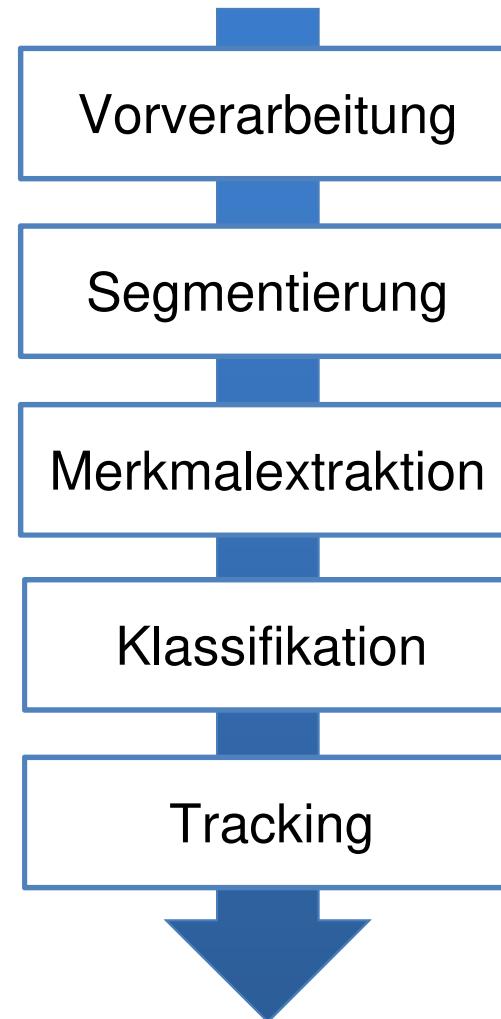
LiDAR bild.



Rohdaten LiDAR – Velodyne

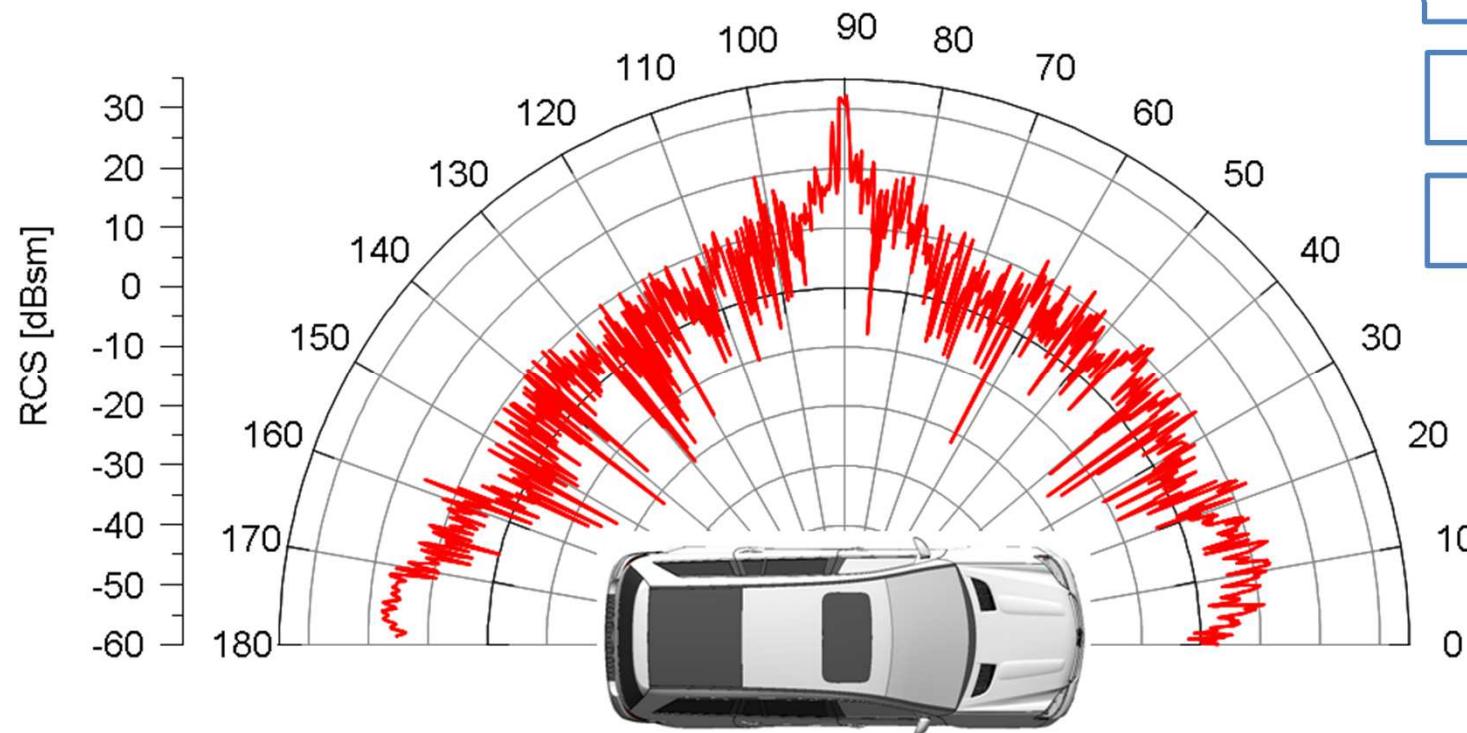


Detektionsverlauf mit RADAR-/LiDAR-Sensoren



Rohdaten RADAR

Radar-Cross-Section (RCS)



Vorverarbeitung

Segmentierung

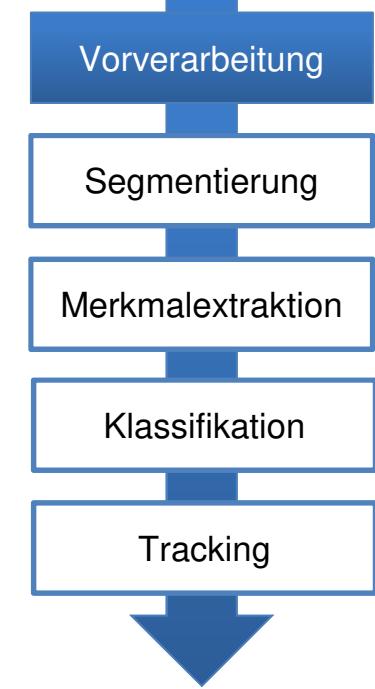
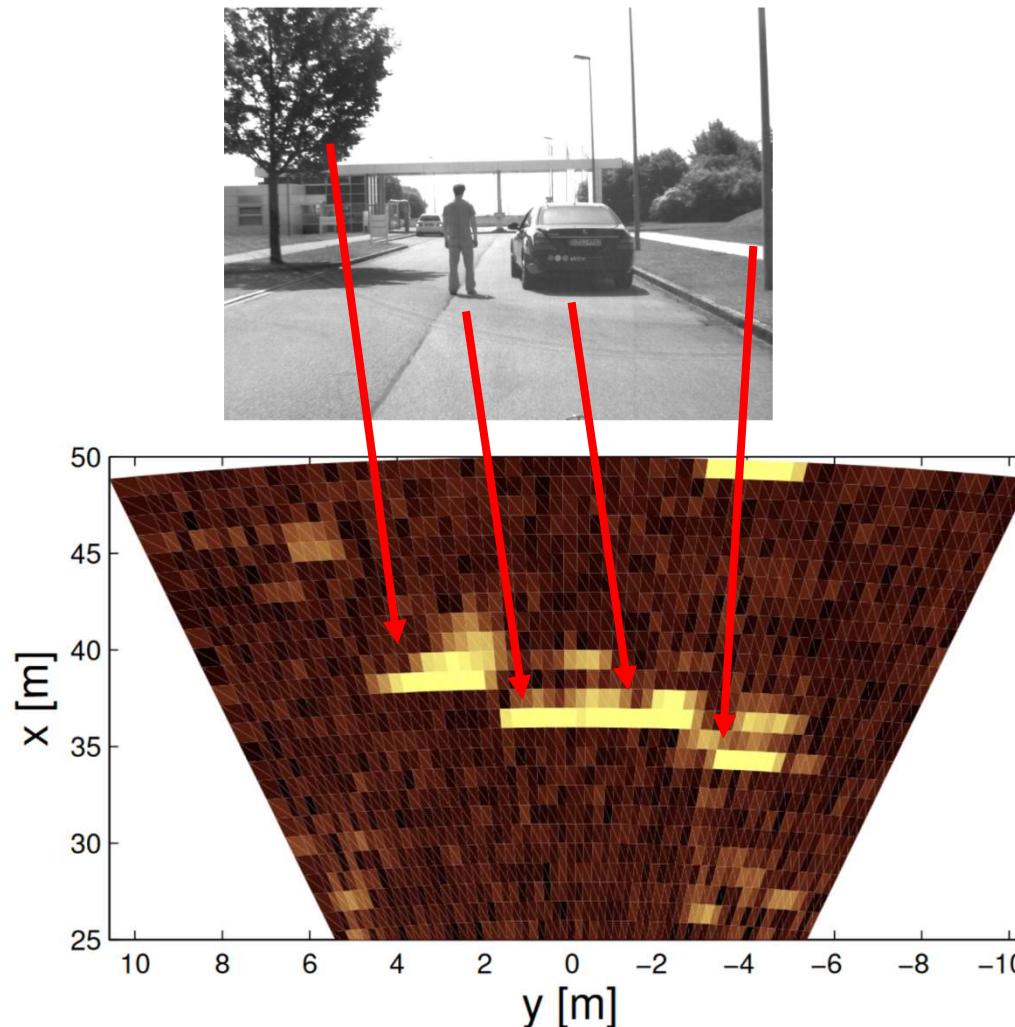
Merkmalextraktion

Klassifikation

Tracking

Quelle: Uni Stuttgart, Institut für Hochfrequenztechnik

Bilderstellung mit RADAR-Messdaten

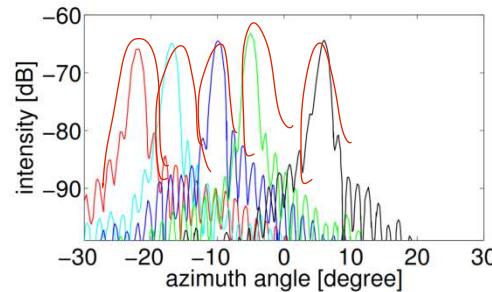


Wegen der niedrigen
azimutalen Auflösung
ist die Breite der
Objekte nicht
erkennbar.

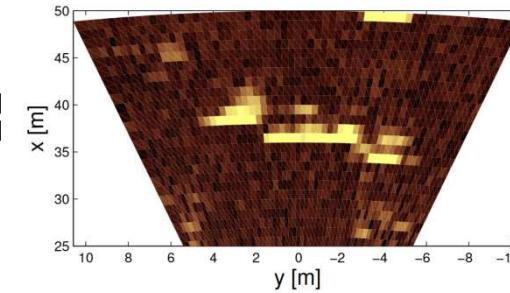
[Hosseini 2012]

Vorverarbeitung – RADAR

Originalbild
↓
?



RADAR-
Antennenbeam (PSF)



Vorverarbeitung

Segmentierung

Merkmalextraktion

Klassifikation

Tracking

$$\text{Kontinuierliche Faltung: } (f * g)(t) \stackrel{\text{def}}{=} \int_{-\infty}^{\infty} f(\tau)g(t - \tau)d\tau$$

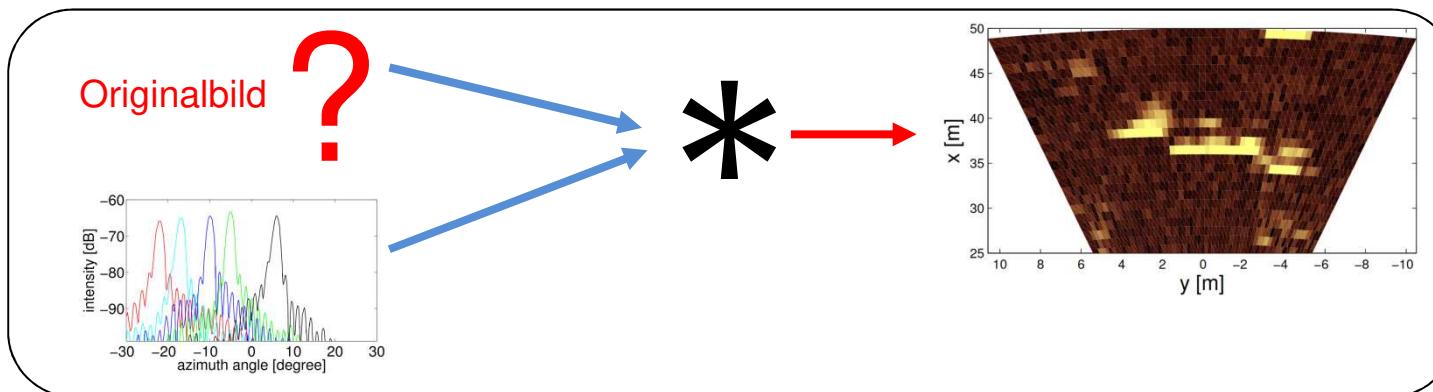
$$\text{Zeitdiskrete Faltung: } (f * g)[n] \stackrel{\text{def}}{=} \sum_{m=-\infty}^{\infty} f[m]g[n - m]$$

[Hosseini 2012]

Vorverarbeitung – RADAR

通过解卷积恢复图像（逆问题）

Bildrestauration durch Entfaltung (inverses Problem)



Vorverarbeitung

Segmentierung

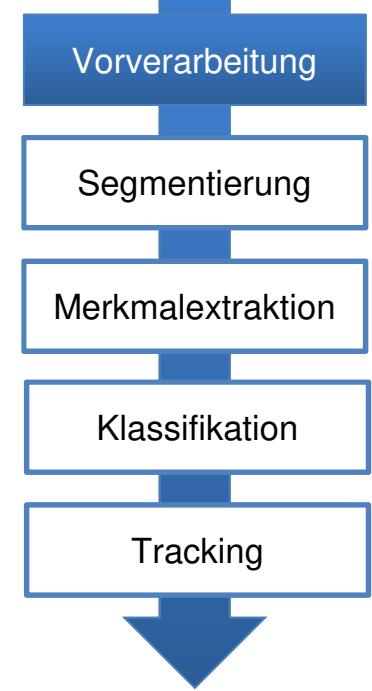
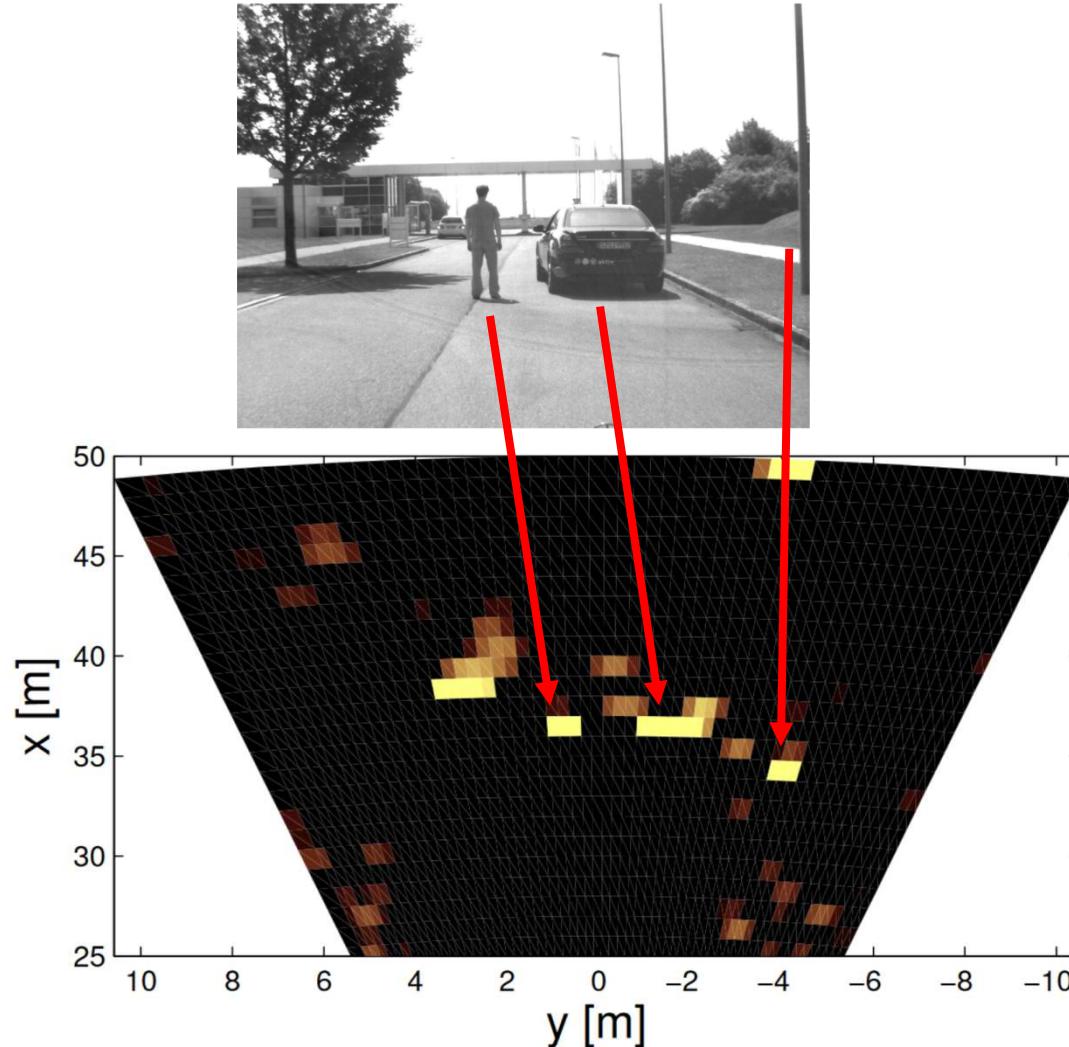
Merkmalextraktion

Klassifikation

Tracking

[Hosseini 2012]

Vorverarbeitung – RADAR



Nach der Bildrestauration
ist die genaue Breite der
Objekte erkennbar.

[Hosseini 2012]

Segmentierung – LiDAR



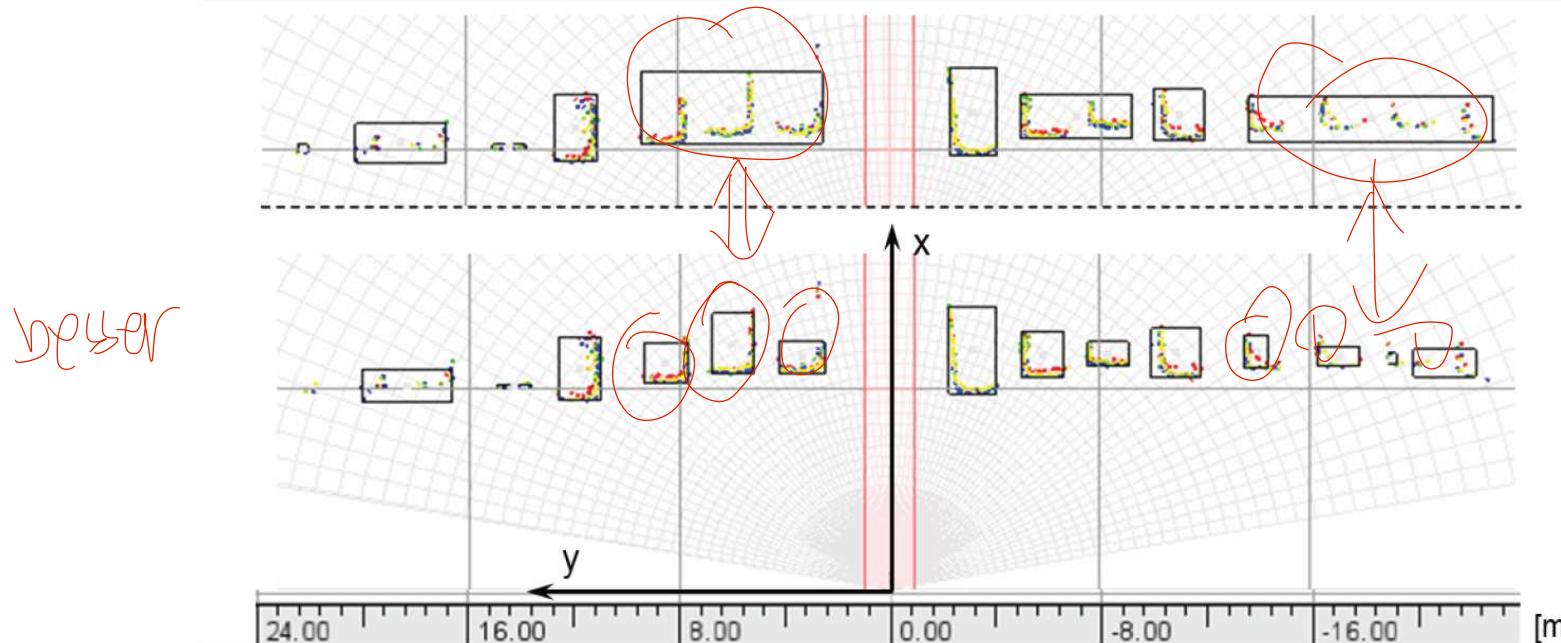
Vorverarbeitung

Segmentierung

Merkmalextraktion

Klassifikation

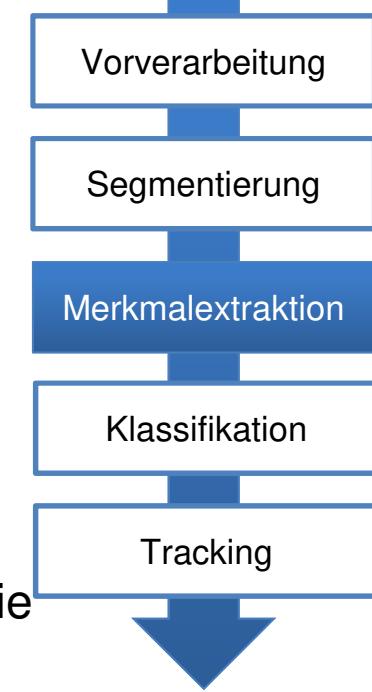
Tracking



[Pietzsch 2015]

Merkmalsextraktion – LiDAR

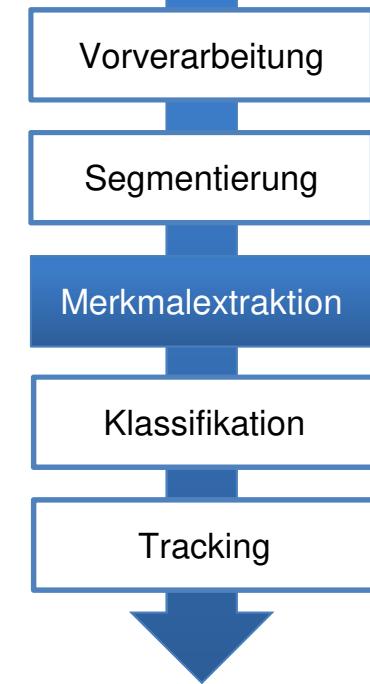
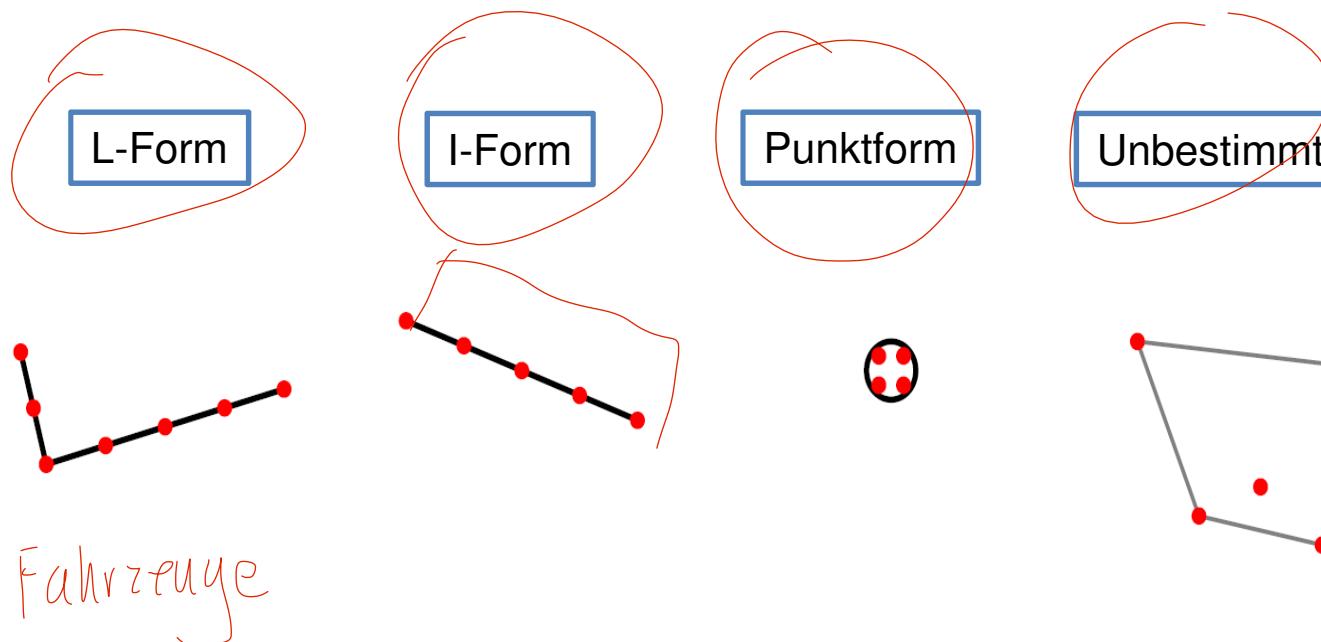
- Winkel des Schwerpunktes
- Länge
- Breite
- Höhe
- Anzahl Punkte
- Orientierungswinkel über Drei-Punkt-Methode
- Orientierungswinkel über Hauptkomponentenanalyse
- Länge der Konturlinie
- Umfang der konvexen Hülle
- Umfang der Bounding Box
- Fläche der konvexen Hülle
- Fläche der Bounding Box
- Dichte über konvexe Hülle
- Dichte über Bounding Box
- Seitenverhältnis
- Kompaktheit über konvexe Hülle
- Kompaktheit über Konturlinie
- Konvexität



[Pietzsch 2015]

Merkmalsextraktion – LiDAR: Shape

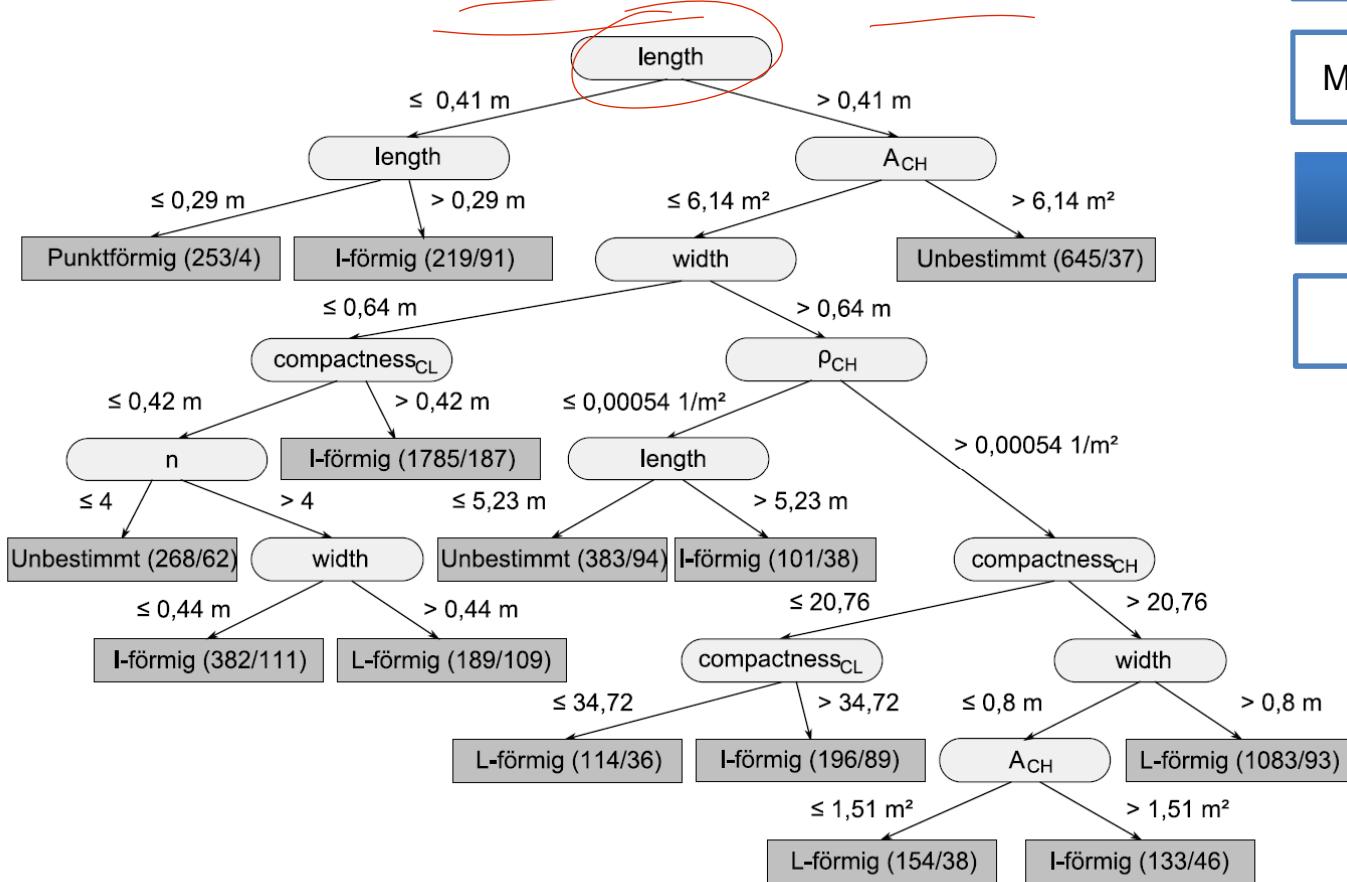
Generieren von Objekthypothesen aus LiDAR-Daten



[Pietzsch 2015]

Klassifikation

Entscheidungsbaum zur Klassifikation von Segmenten



Vorverarbeitung

Segmentierung

Merkmalsextraktion

Klassifikation

Tracking

[Pietzsch 2015]

Sensorik / Wahrnehmung II

Dr.-Ing. Frank Diermeyer
(Andreas Schimpe, M.Sc.)

Agenda

3 Sensorik / Wahrnehmung II

- 3.1 Detektion mit LiDAR und RADAR
- 3.2 Maschinelles Sehen
 - 3.2.1 Kameramodell
 - 3.2.2 Diskretisierung
 - 3.2.3 Stereoskopie
 - 3.2.4 Bildbasierte Mustererkennung
 - 3.2.5 Bewegungsdetektion



Maschinelles Sehen

- Kameramodell
- Diskretisierung
- Stereoskopie
- Bildbasierte Mustererkennung
 - Vorverarbeitung
 - Segmentierung
 - Merkmalsextraktion
 - Klassifikation
- Bewegungsdetektion

Sensorik / Wahrnehmung II

Dr.-Ing. Frank Diermeyer
(Andreas Schimpe, M.Sc.)

Agenda

3 Sensorik / Wahrnehmung II

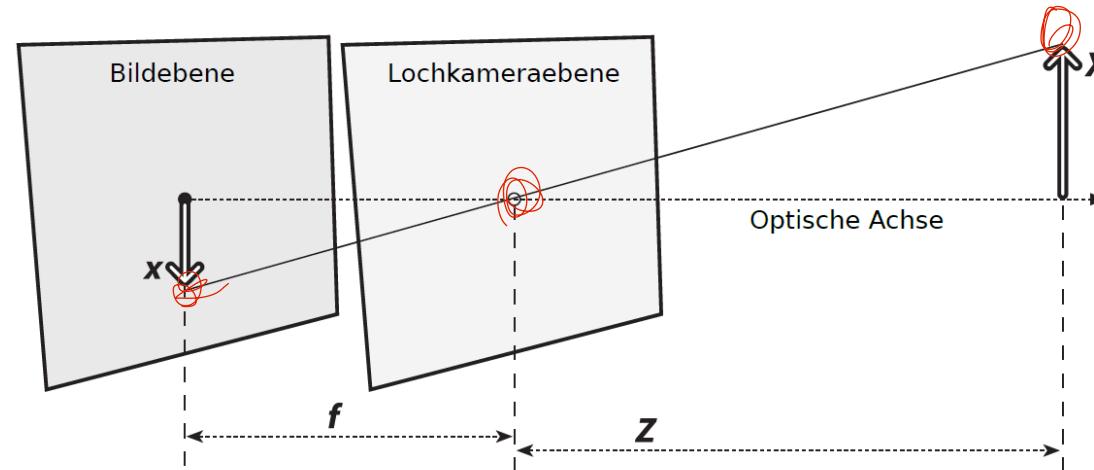
- 3.1 Detektion mit LiDAR und RADAR
- 3.2 Maschinelles Sehen
 - 3.2.1 Kameramodell
 - 3.2.2 Diskretisierung
 - 3.2.3 Stereoskopie
 - 3.2.4 Bildbasierte Mustererkennung
 - 3.2.5 Bewegungsdetektion



Kameramodell – Projektive Abbildung

Lochkameramodell:

- Sehr kleine Blendenöffnung (Loch)
- Scharfe Abbildung
- Geringe Lichtstärke, daher Verwendung von Abbildungsoptik in der Praxis

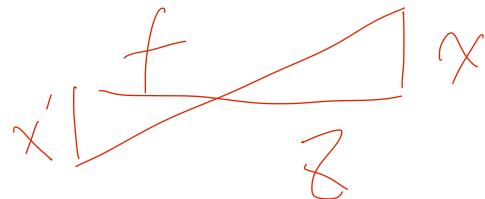


Aufbau:

Eine Lochkamera besteht aus einer undurchsichtigen Ebene, in deren Mitte sich ein kleines Loch befindet. Dies entspricht einer Kamera, deren Blende sehr wenig Licht hindurchlässt. Eine Eigenschaft dieser Anordnung ist die Entstehung eines scharfen Bildes in der Ebene des Strahlungsaufnehmers. In der Praxis lässt sich eine solche Anordnung nicht verwenden, da durch die kleine Öffnung nur sehr geringe Mengen an Licht einfallen und somit die Lichtstärke an der Imager-Ebene zu klein ist. Real wird daher eine geeignete Abbildungsoptik verwendet, die die Vorteile „scharfe Abbildung“ und „große Lichtausbeute“ vereinigt.

Abbildung:

Ein dreidimensionales Objekt wird durch die Blende (Loch) auf einen Bildpunkt in der Bildebene projiziert. In der obigen Zeichnung ist ein Koordinatensystem eingetragen, welches den Ursprung am Ort des Loches besitzt. Die Z-Achse ist senkrecht zur Bildebene orientiert (optische Achse), die Orientierung der Bildkoordinaten (x, y) richtet sich antiparallel zur X bzw. Y-Achse. Durch Anwendung des Strahlensatzes kann die Projektionsgleichung abgeleitet werden.



Kameramodell – Projektive Abbildung

- Projektionsgleichungen für die Bildebene:

$$\left[\frac{x'}{f} = \frac{x}{z}; \quad \frac{y'}{f} = \frac{y}{z}; \quad \lambda' \begin{pmatrix} x' \\ y' \\ f \end{pmatrix} = \begin{pmatrix} X \\ Y \\ Z \end{pmatrix} \text{ mit } \lambda' \in \mathbb{R} \right]$$

- Virtuelles Bild / kalibrierte Kamera (λ : Umrechnungsfaktor):

$$\lambda \begin{pmatrix} x \\ y \\ 1 \end{pmatrix} = \begin{pmatrix} X \\ Y \\ Z \end{pmatrix} \text{ mit } \lambda \in \mathbb{R}$$

- Homogene Koordinaten; das Einfügen einer beliebigen „1“ erlaubt das Hinzufügen einer weiteren Dimension → Quasi-3D-Darstellung
- Abbildungsgleichung mit homogenen Koordinaten:

$$\tilde{x} = (x \quad y \quad 1)^T \quad \lambda \tilde{x} = X$$

Die Projektionsgleichung zeigt, dass bei der Abbildung mit einer Kamera offenbar nur Verhältnisse zwischen dreidimensionalen Koordinaten bestimmt werden können. Für die Bestimmung absoluter Entfernung ist die Kenntnis mindestens einer bekannten Länge im Gegenstandsraum notwendig. Dies kann z. B. durch die Bestimmung der Einbauhöhe der Kamera gegeben sein.

Aus Gründen besserer Anschaulichkeit wird statt der Bildkoordinaten in der Imagerebene häufig eine Ebene auf der anderen Seite der Lochblende gewählt. Zweckmäßig hierfür ist eine Ebene, die parallel zur Lochblende orientiert ist und die Z-Koordinate 1 besitzt. Die daraus entstehenden Bildkoordinaten stellen das sog. virtuelle Bild einer kalibrierten Kamera dar.

Durch die Einführung homogener Koordinaten kann die Darstellung der Abbildungsgleichung deutlich vereinfacht werden.

Sensorik / Wahrnehmung II

Dr.-Ing. Frank Diermeyer
(Andreas Schimpe, M.Sc.)

Agenda

3 Sensorik / Wahrnehmung II

- 3.1 Detektion mit LiDAR und RADAR
- 3.2 Maschinelles Sehen
 - 3.2.1 Kameramodell
 - 3.2.2 Diskretisierung
 - 3.2.3 Stereoskopie
 - 3.2.4 Bildbasierte Mustererkennung
 - 3.2.5 Bewegungsdetektion



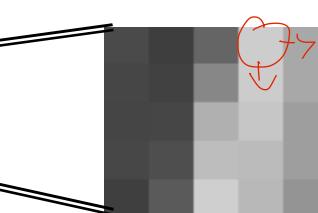
Diskretisierung

- Bildsignale nach bisheriger Betrachtung:
 - Ortskontinuierlich
 - Wertkontinuierlich
 - Zeitkontinuierlich
- Digitalisierung: Diskretisierung in jeder Dimension

根据先前的观察结果生成图像信号:

位置连续
值连续
时间连续

数字化: 各个层面的精细化



75	63	102	206	169
71	66	136	205	169
70	71	177	199	159
72	79	190	188	159
64	91	208	185	149

Helligkeitsdarstellung mit 8 bit



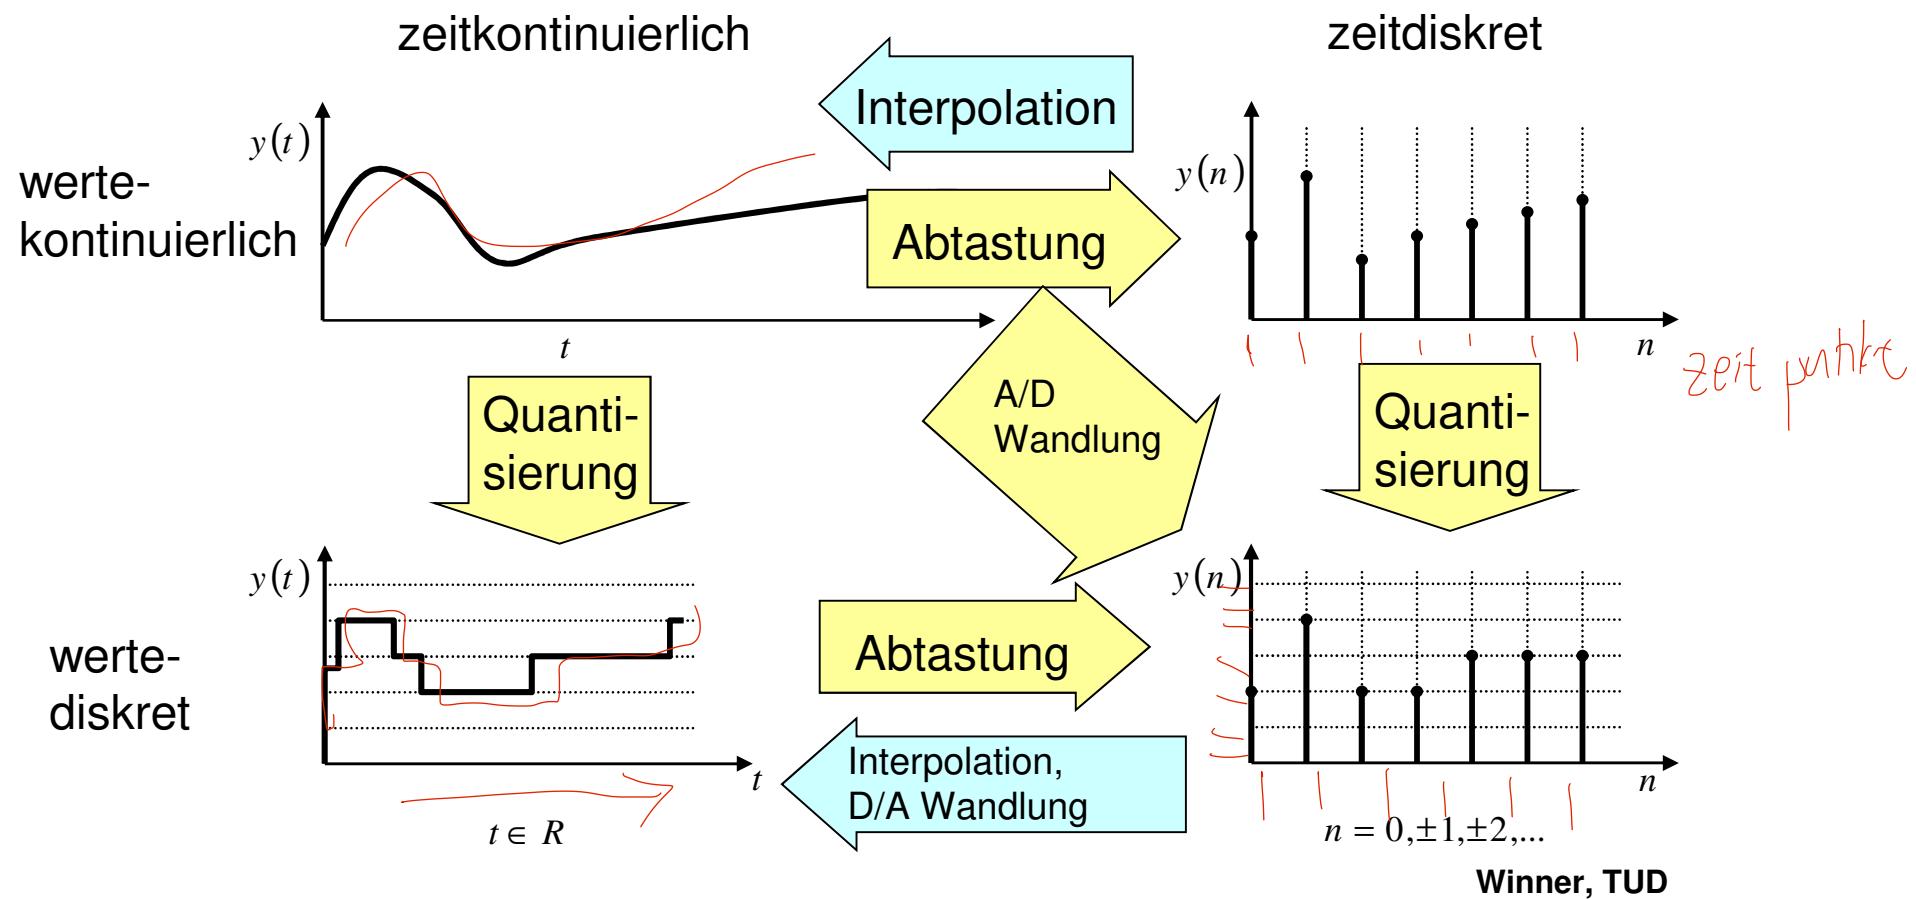
0 128 255

Winner, TUD nach Stiller 2002

Die Projektion eines Bildes auf Bildkoordinaten ist zunächst ein kontinuierlicher Vorgang in Ort, Zeit und Amplitude. Um den nachfolgenden Algorithmen jedoch eine Grundlage für die Bildverarbeitung zu liefern, müssen die empfangenen Bilder durch Abtastung und Quantisierung digitalisiert werden. Die Diskretisierung im Bezug auf den Ort geschieht dabei bereits durch den Aufbau des Imager-Chips, der ja eine endliche Anzahl von Elementarzellen besitzt. Zeitlich werden die Bilder sequentiell in den Speicher gelesen und werden so in dieser Dimension diskretisiert. Die ermittelten Werte der Helligkeit eines bestimmten Ortsbereiches müssen ebenfalls in eine Form gebracht werden, die Rechner weiterverarbeiten können. Üblicherweise wird das relevante Spektrum dabei in eine definierte Anzahl von Stufen quantisiert. Im obigen Beispiel kann die Helligkeit eines bestimmten Pixels eine von insgesamt 256 Stufen annehmen, da die interne Repräsentation eine Genauigkeit von 8 bit aufweist ($2^8 = 256$).

Diskretisierung

A/D-Wandler



Diskretisierung im Werte- und Zeitbereich

Vorteil: Reduktion der Datenmenge

Nachteil: Auflösung unterliegt durch die Abtastung dem Nyquist-Kriterium. Ist die geometrische „Frequenz“ im Sinne der Größe von optischen Mustern zu groß für die diskrete Abtastung in Form von Pixelabständen, tritt Aliasing auf.

Ein bekanntes, häufig sichtbares Beispiel dafür ist die nicht eindeutige, mit Moiré-Effekten gestörte Darstellung von eng karierten oder gestreiften Anzügen bei Fernsehaufnahmen.

Diskretisierung - Datenrate

- $D = B \cdot P \cdot N \cdot F$
 - D: Datenrate
 - B: Anzahl der Pixel für ein Bild (Pixel: Abkürzung für picture element, Bildpunkt)
 - P: Anzahl der Bytes pro Pixel (P)
 - N: Anzahl der Kameras
 - F: Einlesefrequenz
- Mögliche Konfigurationen für Straßenerkennung:

Zum Vergleich HDTV:

B = 384x286 Pixel

P = 1 Byte/Pixel (s/w)

N = 1

F = 25 Hz (PAL-Norm)
Norm)

D = 2,62 MiByte/s

B = 384x286 Pixel

P = 4 Byte/Pixel (Farbe)

N = 1

F = 25 Hz (PAL-Norm)
D = 10,47 MiByte/s

B = 1920x1080 Pixel

P = 2 Byte/Pixel (luma + chroma)

N = 1

F = 30 Hz (HD-Norm)
D = 118,65 MiByte/s

(1 MiByte = 1.048.576 Byte = 2^{20} Byte)

Winner, TUD nach Maurer 2003

Sensorik / Wahrnehmung II

Dr.-Ing. Frank Diermeyer
(Andreas Schimpe, M.Sc.)

Agenda

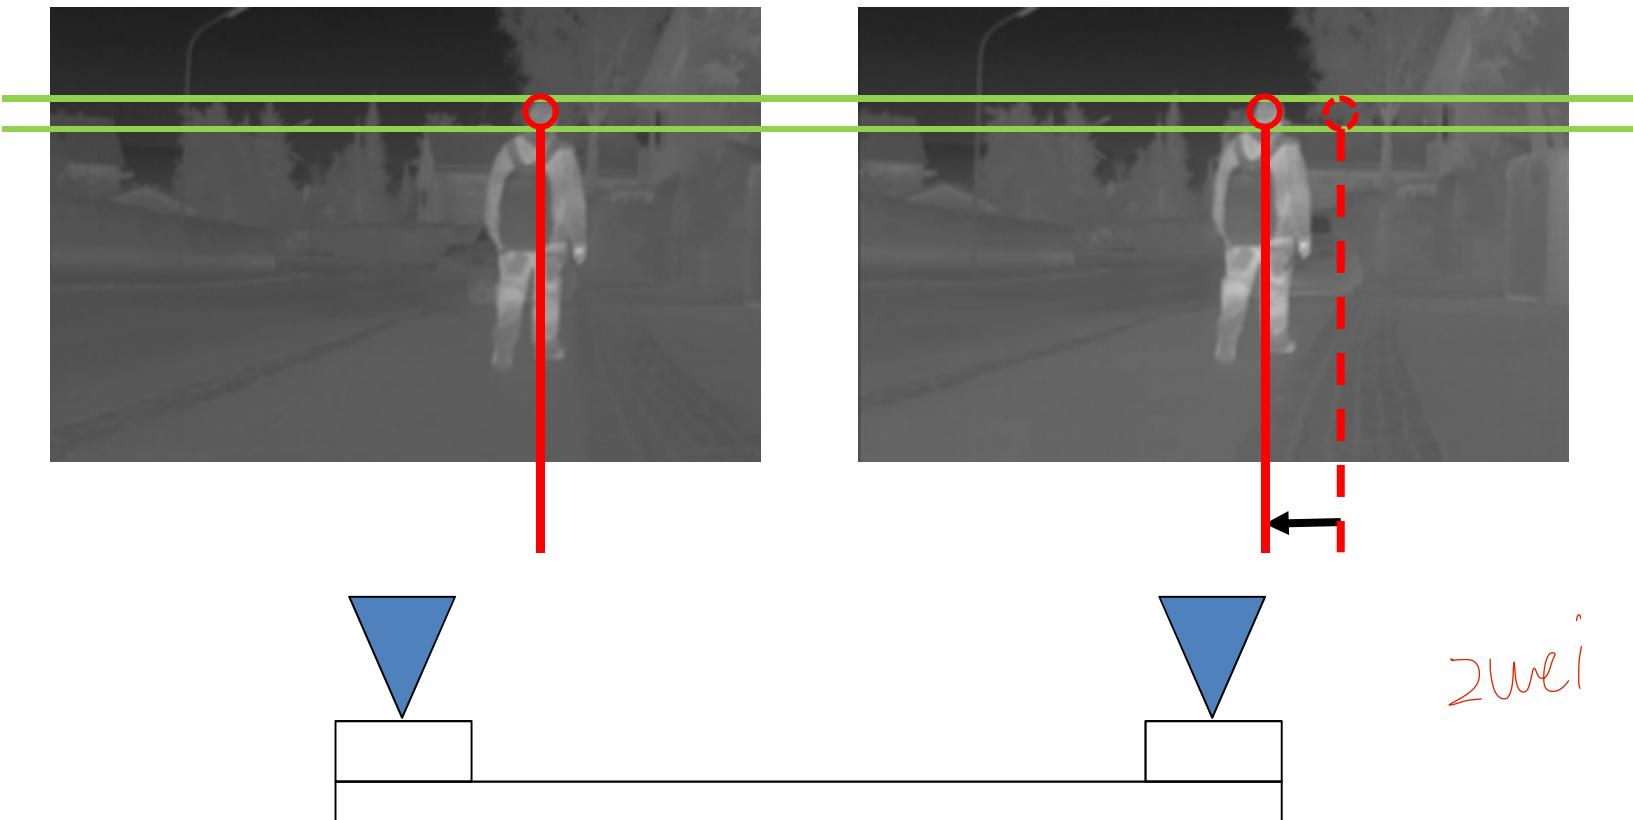
3 Sensorik / Wahrnehmung II

- 3.1 Detektion mit LiDAR und RADAR
- 3.2 Maschinelles Sehen
 - 3.2.1 Kameramodell
 - 3.2.2 Diskretisierung
 - 3.2.3 Stereoskopie
 - 3.2.4 Bildbasierte Mustererkennung
 - 3.2.5 Bewegungsdetektion



Stereoskopie

Parallaxe



Stereoskopie

Triangulation

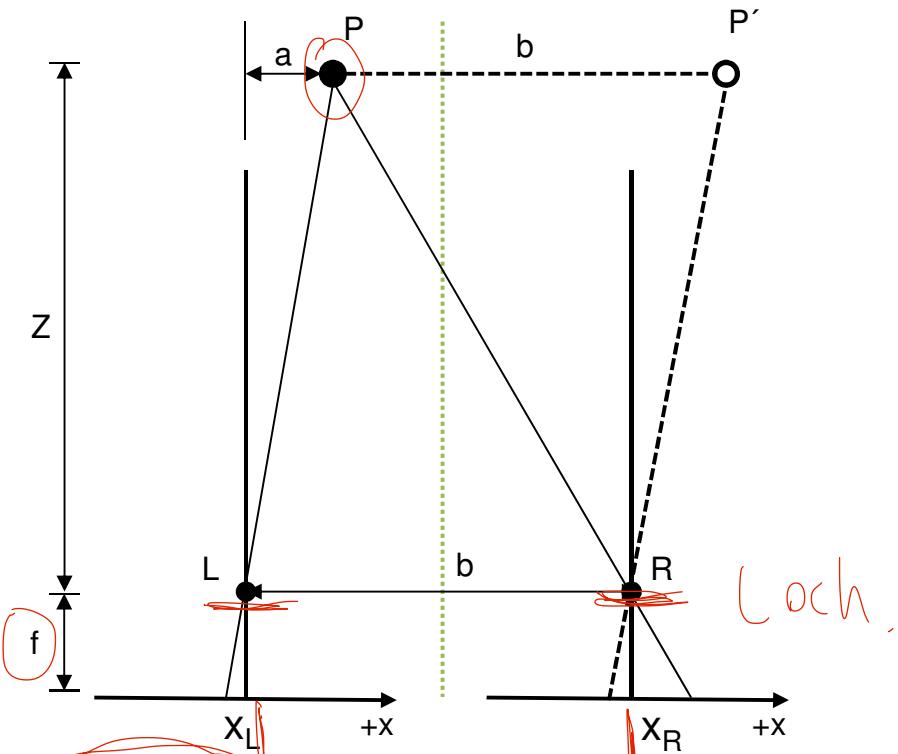
Binokulare Perspektive (vereinfacht für parallele optische Achsen)

- Parameter und Eigenschaften
 - Basis(abstand): b
 - Bild-/Brennweite: f
 - nur horizontale Disparitäten
 - alle Punkte $z < \infty$ sind disparat
 - Disparität: $D := x_L - x_R$
- Abstand durch Triangulation:

$$\frac{a}{Z} = \frac{-x_L}{f} \wedge \frac{b-a}{Z} = \frac{x_R}{f}$$

Einsetzen:

$$b + Z \frac{x_L}{f} = Z \frac{x_R}{f} \Rightarrow Z = \frac{bf}{x_R - x_L} = -\frac{b \cdot f}{D} \Rightarrow |Z| \propto D^{-1}$$

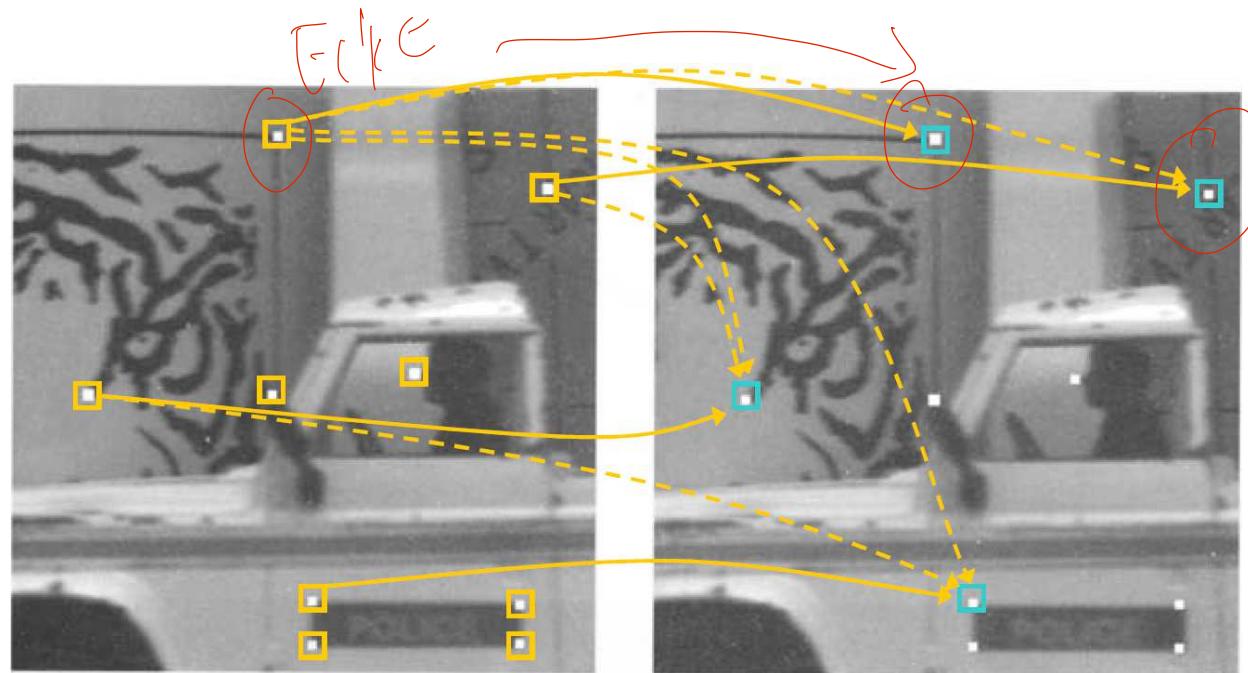


Quelle: Neumann, Uni Ulm

Bei der Stereoskopie, die zu den passiven Verfahren der 3D-Szenenrekonstruktion gezählt wird, werden simultan zwei oder mehr Bilder von entsprechenden Kamerapositionen aus aufgenommen, die um eine Basisbreite versetzt sind. Gelingt es, die Pixel, die zu gleichen Objektbereich gehören, einander zuzuordnen, so lassen sich aus der Differenz der Pixel-Lage ($x_1 - x_2$) und den intrinsischen und extrinsischen Kalibrierungsparametern die räumliche Position des Objekts bestimmen.

Stereoskopie – Korrespondenzfindung

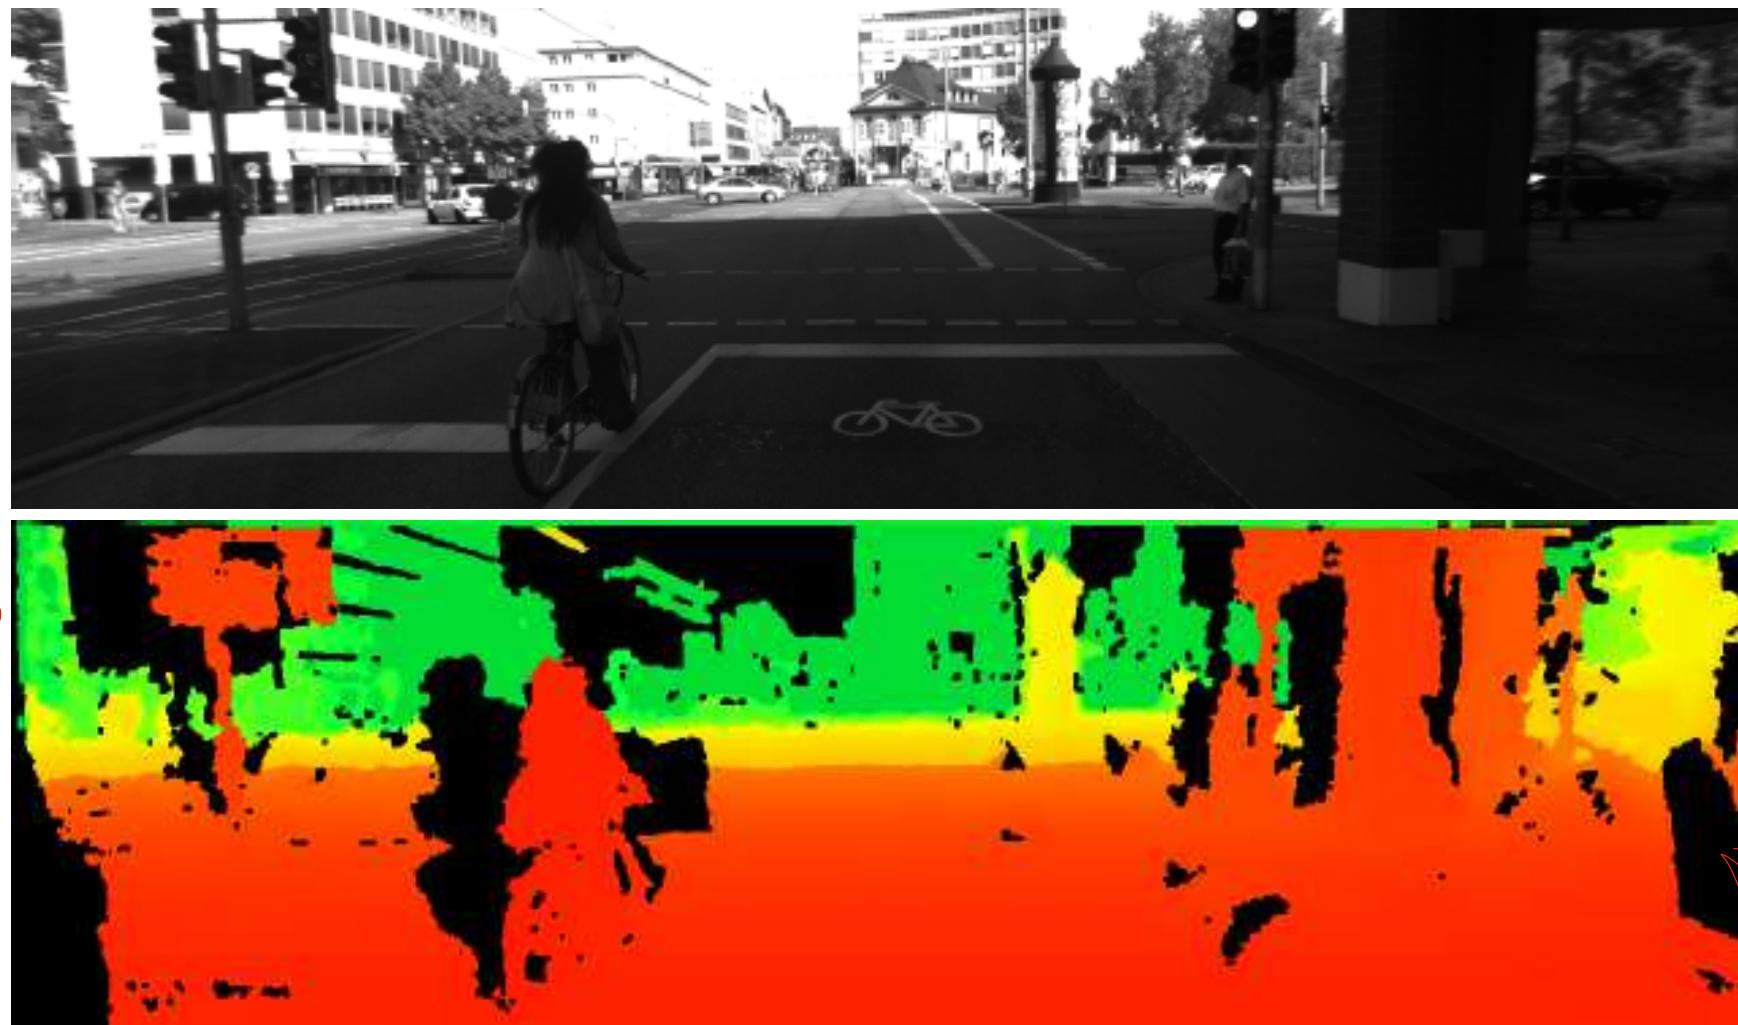
- Extraktion relevanter (auffälliger) Punkte
 - Bestimmung korrespondierender Punkte (spärliche Anzahl) und Zuordnung im linken und rechten Bild eines Stereobild-Paars
- 提取相关（显著）点
- 确定对应点（稀疏数）并分配到立体图像对的左右图像中



Quelle: Neumann, Uni Ulm

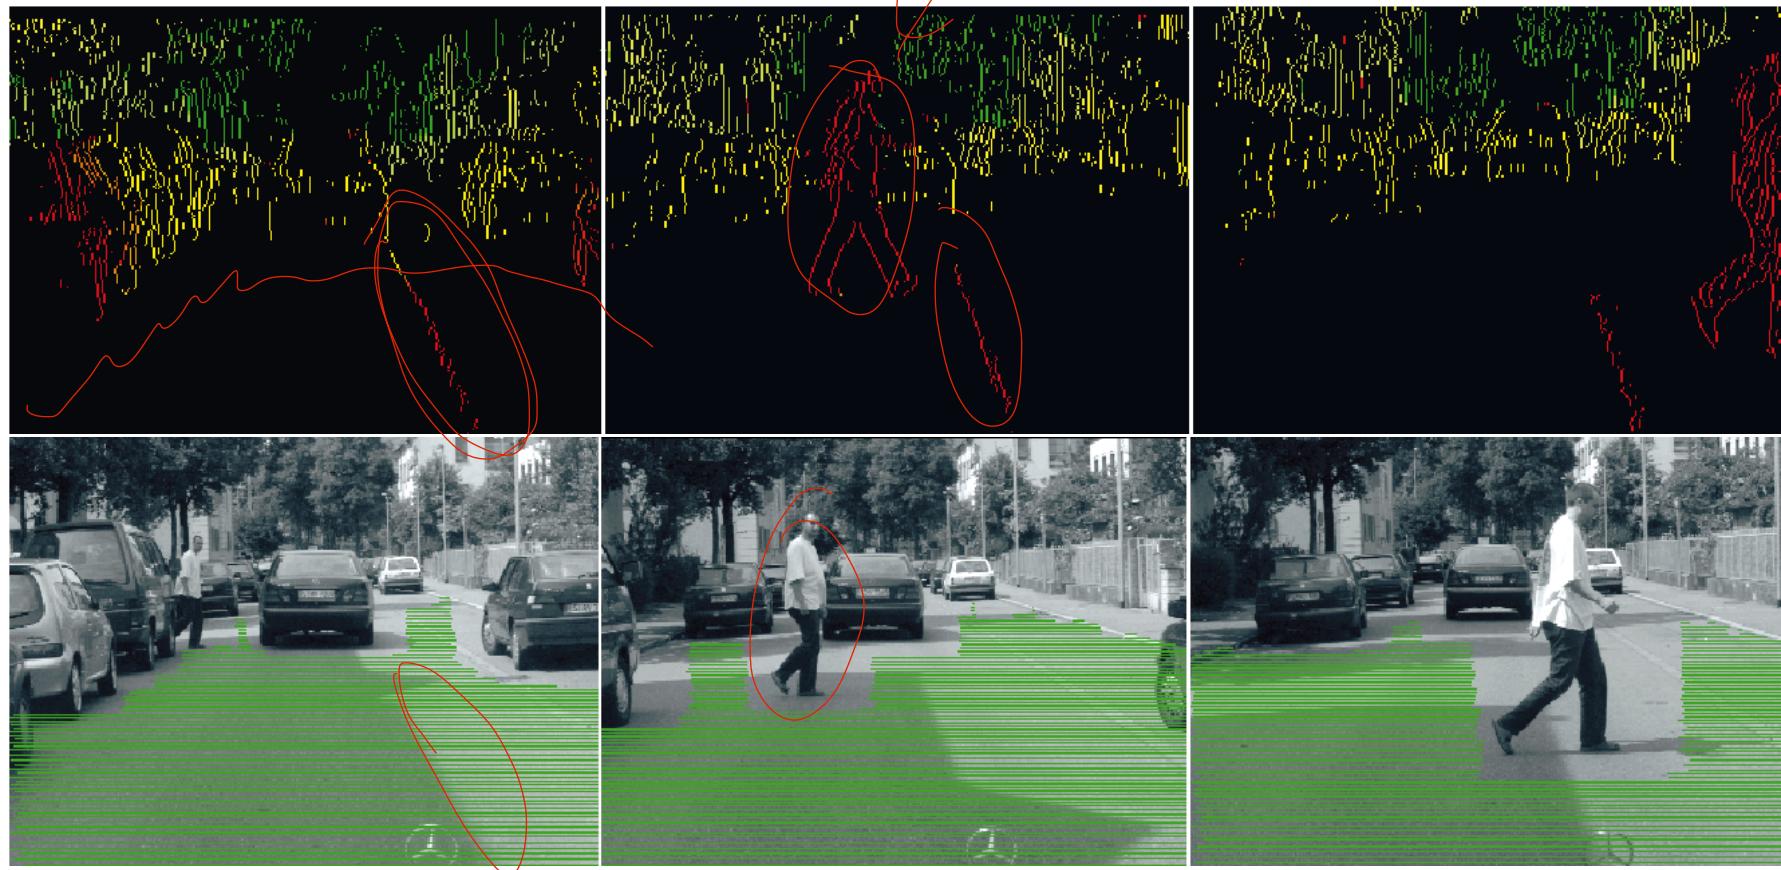
差距图

Disparitätskarte



Stereo-Vision arbeitet mit Bildpaaren, die gleichzeitig von zwei versetzt angeordneten Kameras aufgenommen werden. Mittels Korrelation von Bildmerkmalen (z.B. signifikante Kanten) wird eine sogenannte Disparitätskarte erzeugt. Die Disparitätskarte zeigt den Versatz der Kanten beider Bilder. Generell gilt: je größer die Disparität, desto geringer der Abstand. Die Visualisierung zeigt nahe Objekte rot und entfernte Objekte in grün-schwarz.

Stereoskopie – Auswertung



[DaimlerChrysler 2001]

Obere Bildreihe:

Beim stereoskopischen Sehen (oben) werden die Entferungen zu allen Objekten im Umfeld der Straße exakt gemessen – rote Objekte befinden sich im Vordergrund, grüne sind am weitesten weg. Aus dieser Basisinformation kann das System den freien, verfügbaren Straßenraum ermitteln.

untere Bildreihe:

In dieser Sequenz wird deutlich, wie schnell Hindernis- und Bewegungserkennung das zwischen zwei parkenden Autos in die Fahrbahn hineinrollende Fahrzeug detektieren. Mit dem Auge ist das Fahrzeug im ersten Bild kaum auszumachen. Die Mustererkennung hat dagegen bereits das Fahrzeugheck erfasst.

Weitere Verfahren sind „dense stereo“, bei dem jedem Bildpunkt eine Tiefeninformation zugeordnet wird, sowie „6D Stereo“, eine Kombination aus Stereoskopie und optischem Fluss, wobei Informationen sowohl zum Ort als auch Geschwindigkeit von Objekten in je 3 Dimensionen vorliegen.

- 计算要求适中
- 校准问题
- 封装（基底宽度）
- 成本适中
- 无分类
- 可能与车辆设计（安装位置）冲突

Stereoskopie: Vor- und Nachteile

Verfahren	Vorteile	Nachteile
Stereoskopie	<ul style="list-style-type: none"> • Tiefeninformation aus Disparität • Robustheit der Verfahren • Geringe Modellinformationen zur Initialisierung erforderlich <p style="color: red; margin-left: 20px;">- 从差异中获取深度信息 - 方法的鲁棒性 - 初始化所需的模型信息很少</p>	<ul style="list-style-type: none"> • Mäßig rechenaufwendig • Kalibrierproblem • Package (Basisbreite) • Mäßige Kosten • Keine Klassifikation • Mögliche Konflikte mit Fahrzeugdesign (Einbauorte) 

Winner, TUD; Bild: Mercedes-Benz

Sensorik / Wahrnehmung II

Dr.-Ing. Frank Diermeyer
(Andreas Schimpe, M.Sc.)

Agenda

3 Sensorik / Wahrnehmung II

3.1 Detektion mit LiDAR und RADAR

3.2 Maschinelles Sehen

 3.2.1 Kameramodell

 3.2.2 Diskretisierung

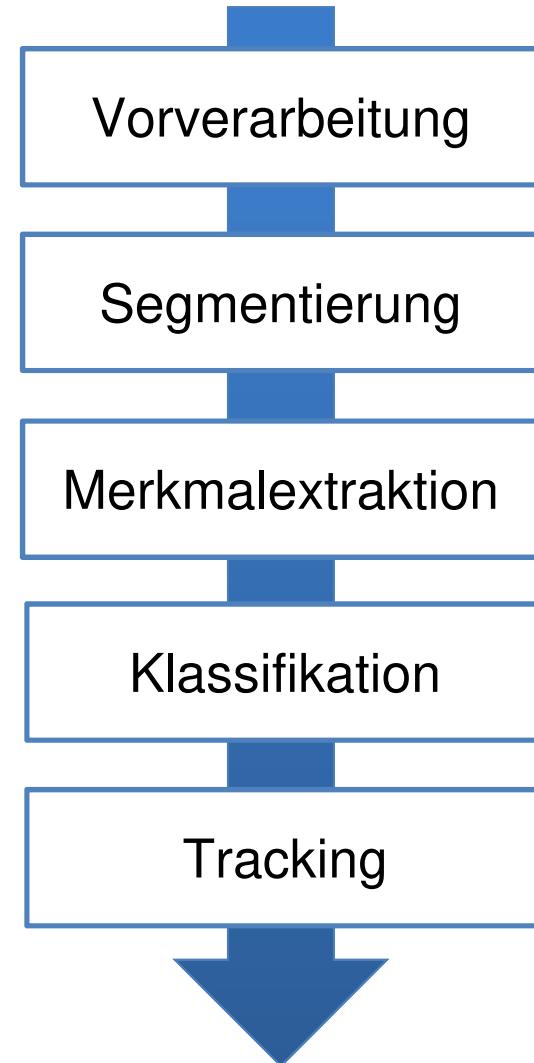
 3.2.3 Stereoskopie

 3.2.4 Bildbasierte Mustererkennung

 3.2.5 Bewegungsdetektion



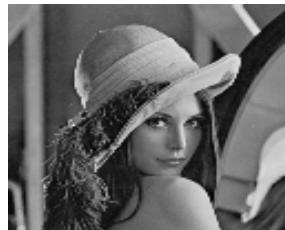
Bildbasierte Mustererkennung



Vorverarbeitung

Auflösung: Ort und Helligkeit

- Verringerung der Ortsauflösung (Anzahl Bildpunkte):



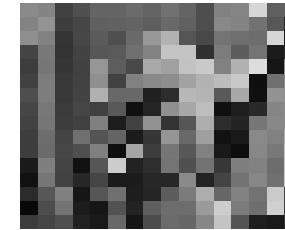
$$128 \times 128 \times 8 \\ = 131072$$



$$64 \times 64 \times 8 \\ = 32768$$



$$32 \times 32 \times 8 \\ = 8192$$



$$16 \times 16 \times 8 \\ = 2048$$

- Verringerung der Helligkeitsauflösung (bit je Bildpunkt):



$$128 \times 128 \times 4 \\ = 65536$$



$$128 \times 128 \times 3 \\ = 49152$$



$$128 \times 128 \times 2 \\ = 32768$$



$$128 \times 128 \times 1 \\ = 16384$$

Vorverarbeitung

Segmentierung

Merkmalextraktion

Klassifikation

Tracking

亮度分辨率

Winner, TUD nach Stiller 2002

Um Datenmengen zu verringern, kann die Präzision der Diskretisierung in verschiedenen Dimensionen (Ort, Helligkeit) reduziert werden. In der oberen Bildreihe wird die Zahl der Pixel verkleinert, in der unteren die Auflösung der Helligkeit.

Vorverarbeitung

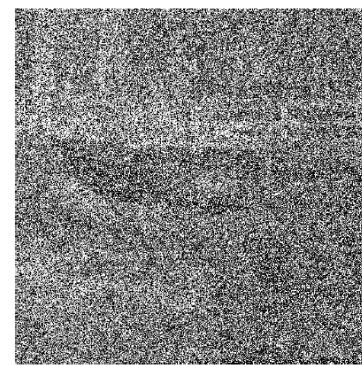
Rauscheffekt



Originalbild B

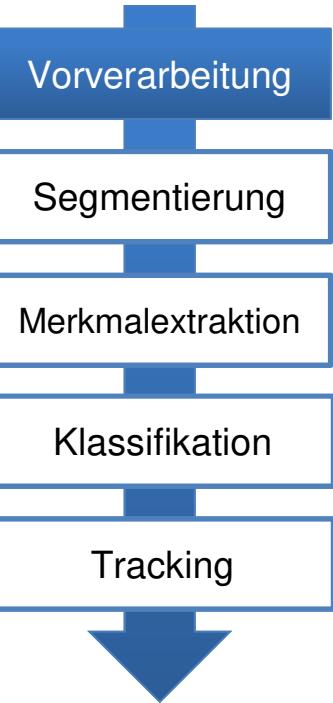
令人陶醉的效果

Filter



Verrausches Bild
 $B_F = \text{Filter}(B) + \eta$

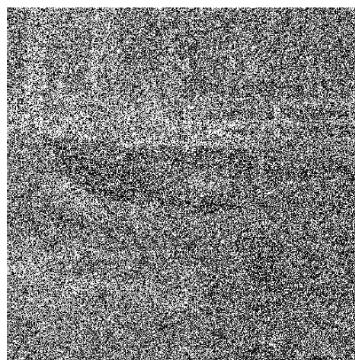
- Filter: Scanner, digitale Kameras, Internetübertragung...
- η : additives Rauschen = unvorhersehbare Filterfehler
- Ziel: Umkehrung der Filtertransformation und Rauschunterdrückung



[Stöckler]

Vorverarbeitung

Rauschunterdrückung



Verrausches Bild

$$B_F = B + \eta$$

降低噪音

Filter



Entrausches Bild

$$\approx B$$

- Filter: Transformation zur Rauschunterdrückung
- Hinweis: bei datenunabhängigem/nicht-additivem Rauschen sind andere Verfahren nötig.

Vorverarbeitung

Segmentierung

Merkmalextraktion

Klassifikation

Tracking

图像分割方法分为

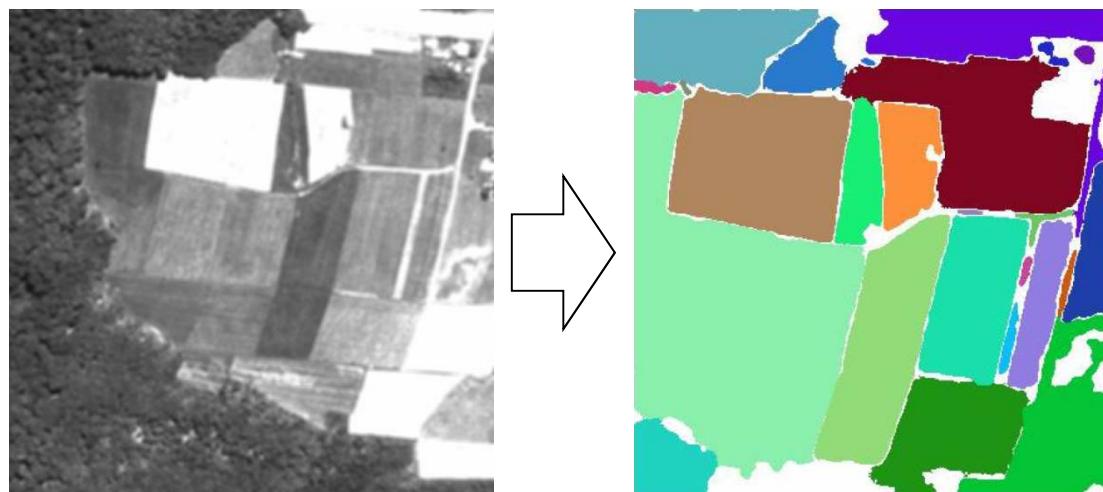
- 阈值法
- 面向边缘的方法
- 面向区域的方法
- 基于模型的方法
- 纹理导向方法和...

Segmentierung

Bei der Bildsegmentierung wird jeder einzelne Bildpunkt darauf überprüft, ob er einem uns interessierenden Bildobjekt angehört.

Verfahren zur Bildsegmentierung werden unterteilt in:

- Schwellwertverfahren
- Kantenorientierte Verfahren
- Regionenorientierte Verfahren
- Modellbasierte Verfahren
- Texturorientierte Verfahren und...



Vorverarbeitung

Segmentierung

Merkmalextraktion

Klassifikation

Tracking

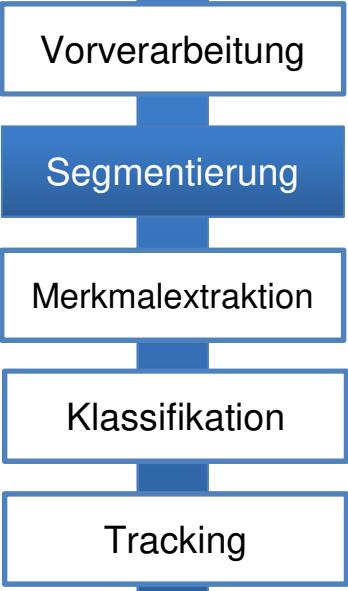
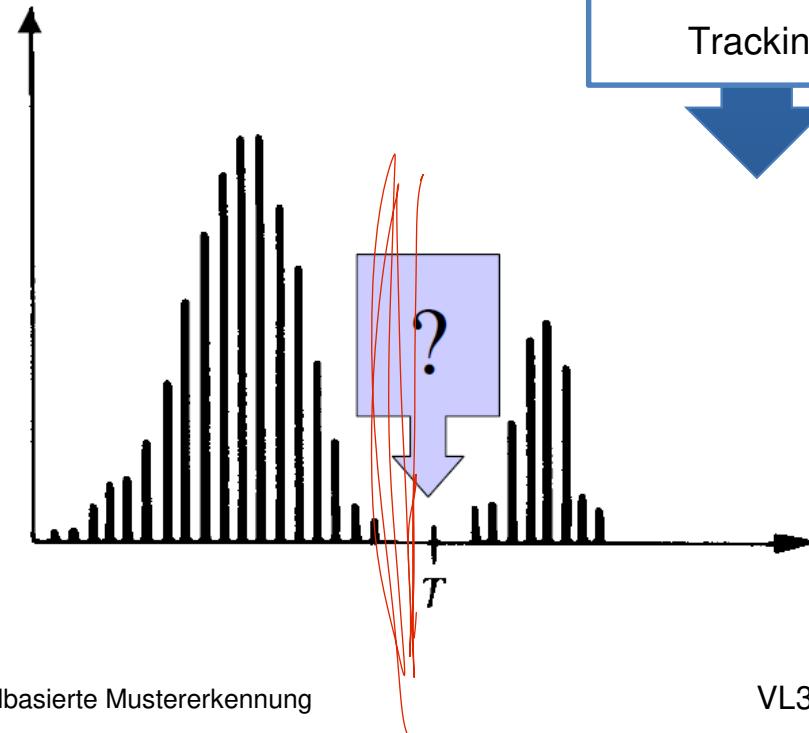
Segmentierung

Schwellwertverfahren (Thresholding)

閾值程序

$$g(x, y) = \begin{cases} 1, & \text{falls } f(x, y) \geq T \Rightarrow \text{Bildpunkt} \\ 0, & \text{falls } f(x, y) < T \Rightarrow \text{Hintergrundpunkt} \end{cases}$$

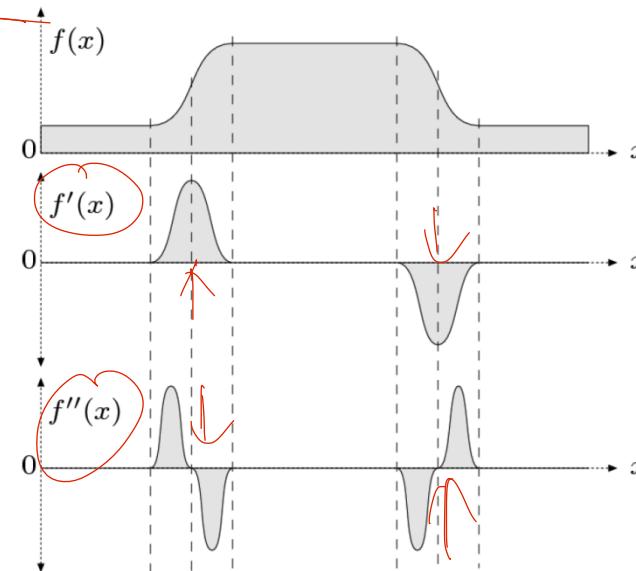
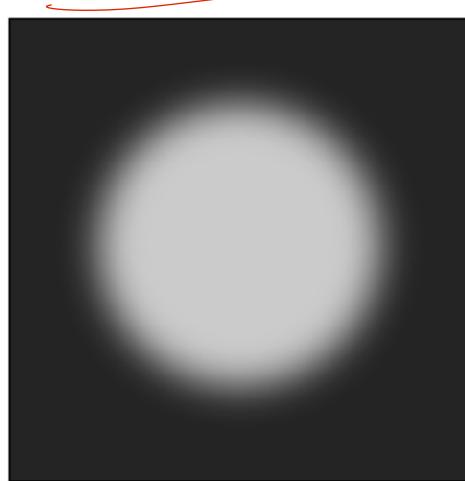
Der Schwellwert wird auf Grundlage des Helligkeitshistogramms des Bildes identifiziert:



Segmentierung

边缘导向法

Kantenorientiertes Verfahren



Funktion $f(u)$ entspricht Grauwert in einer Zeile

Funktion $f'(u)$ entspricht erster Ableitung von $f(u)$

→ Kantendetektion durch erste Ableitung des Bildes

Vorverarbeitung

Segmentierung

Merkmalextraktion

Klassifikation

Tracking

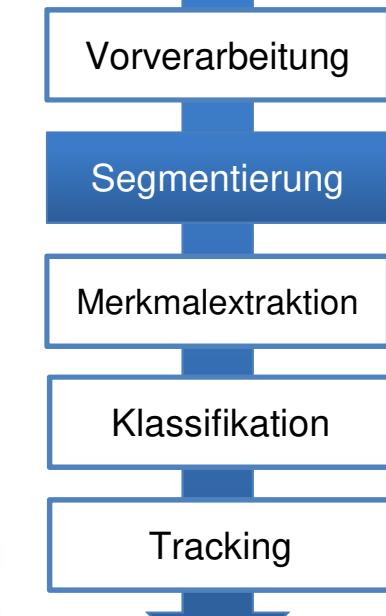
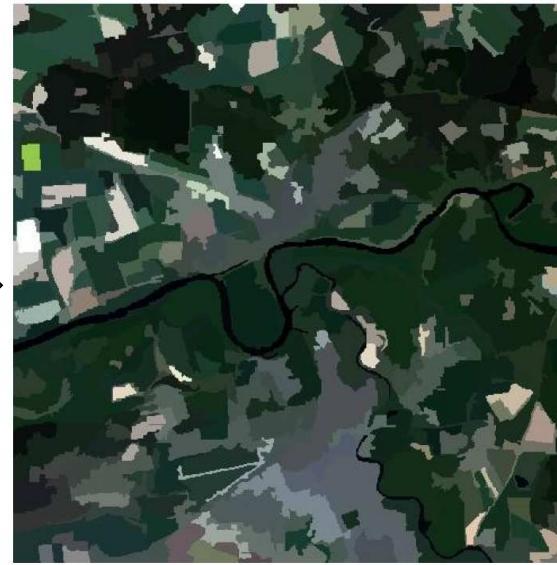
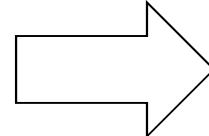
**Mehr Informationen zu kantenbasierten Verfahren im Abschnitt
Merkmalsextraktion!**

[Herrmann]

Segmentierung

Regionenorientierte Verfahren

- Region-Growing
- Split-and-Merge
- Textursegmentierung
-



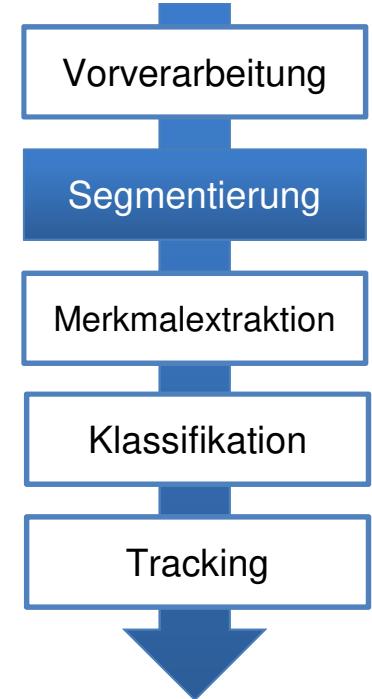
- 将种子点定义为起始区域
- 如果所考虑的点的灰度值与邻近区域灰度值的平均值之间的距离函数值低于阈值，则邻近点将被添加到区域中
- 如果点已经属于另一个区域（可能的区域联盟），也会被添加进来
- 重复增长，直至不再可能。
- 选择合适的发芽点很重要
- 发芽点的数量是区域数量的上限

Segmentierung

Regionenorientiertes Verfahren nach dem Region-Growing-Prinzip

- Festlegung von Keimpunkten als Startregion
- Benachbarte Punkte werden zur Region hinzugefügt, wenn der Wert der Distanzfunktion zwischen dem Grauwert des betrachteten Punktes und dem Mittelwert der Grauwerte der benachbarten Region unter einem Schwellwert liegt
- Punkte werden auch hinzugefügt, wenn sie schon zu einer anderen Region gehören (mögliche Vereinigung von Regionen)
- Wiederholung des Wachstums, bis keines mehr möglich ist.

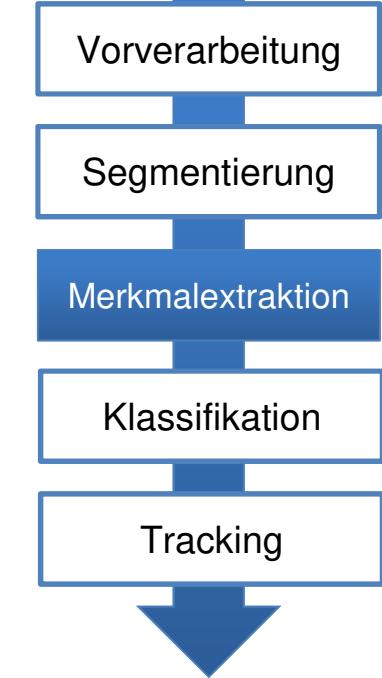
- Wahl geeigneter Keimpunkte wichtig
- Anzahl Keimpunkte ist obere Schranke für Anzahl der Regionen



[Kürbig, Sauter 2005]

Merkmalsextraktion

- Sehr hoher Informationsgehalt im Bild
- Herausforderung: Datenreduktion / Informationsextraktion



Winner, TUD nach Maurer 2003

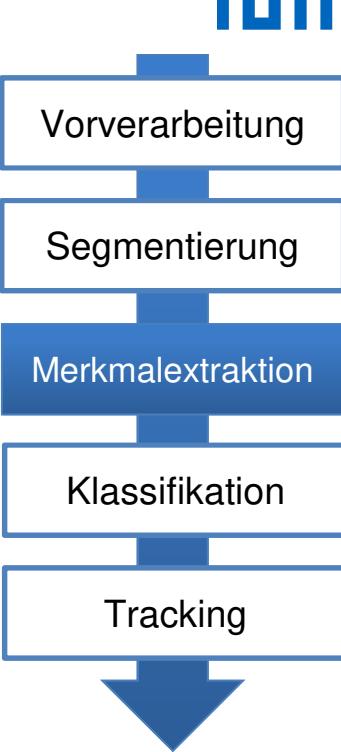
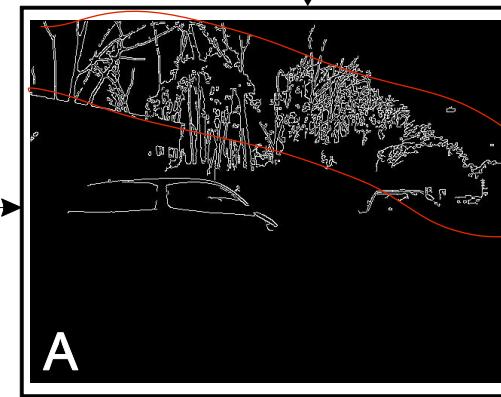
Ein Videosensor ist ein sog. nichtselektiver Sensor, d.h. er erfasst in jedem Abtastschritt das gesamte Bild, unabhängig davon, was darauf zu sehen ist. Dadurch entstehen sehr große Datenmengen, die von den folgenden Algorithmen verarbeitet werden müssen. Aus der Tatsache, dass der Mensch aus einem Bild wie dem obigen näherungsweise die gesamte Verkehrssituation ableiten kann, wird deutlich, dass der Informationsgehalt eines solchen Pixelbildes sehr groß ist. Daher besteht die Herausforderung bei der Entwicklung von Bildverarbeitungsalgorithmen darin, durch Extraktion der bedeutsamen Informationen diese Datenmenge zu reduzieren.

Dies wird z.B. durch die Suche nach erwarteten Inhalten („rot und rund“) oder durch das Ignorieren von einheitlichen Bereichen mit wenig Information (große, annähernd gleichfarbige Flächen) erreicht.

Merkmalsextraktion

Bedeutung

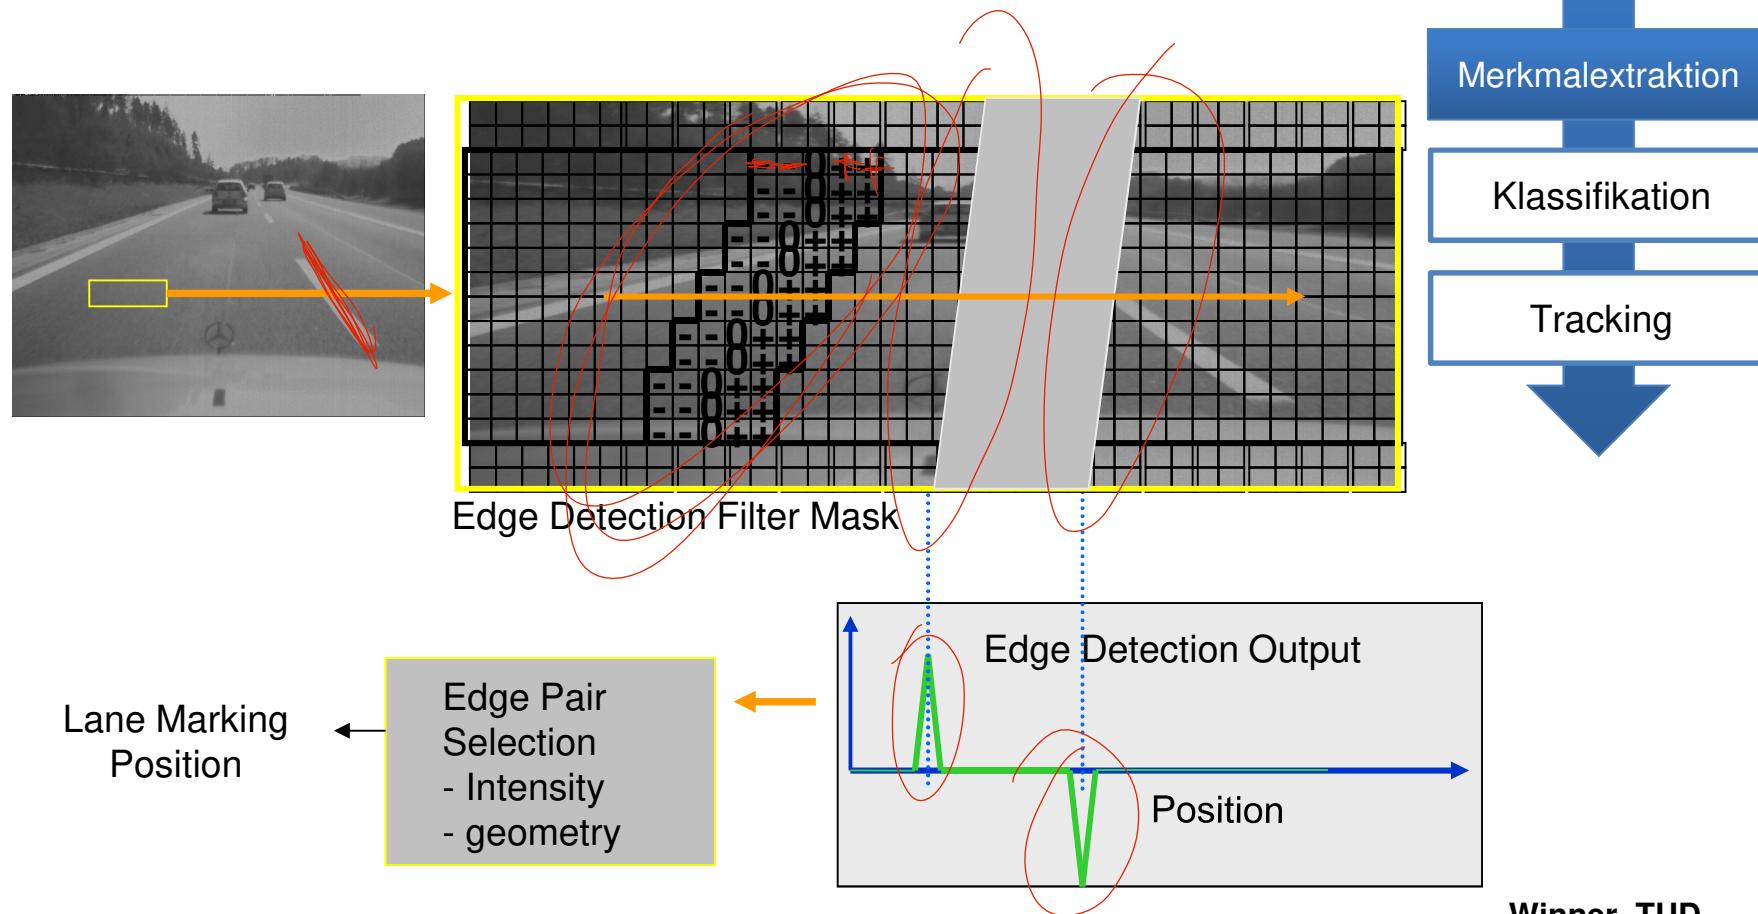
- Charakterisiert durch signifikante Änderung des Bildsignals über Bildkoordinaten
边缘和角落 (边缘和角落)
- Wichtigste Merkmale: Kanten und Ecken, aber auch z. B. Kreise
- Beispiele für Algorithmen:
 - Harris-Eckendetektor
 - Canny-Kantendetektor



Winner, TUD nach [Winner 2009]

Merkmalsextraktion – Kantendetektion

Kantendetektionsoperator: Funktionsweise

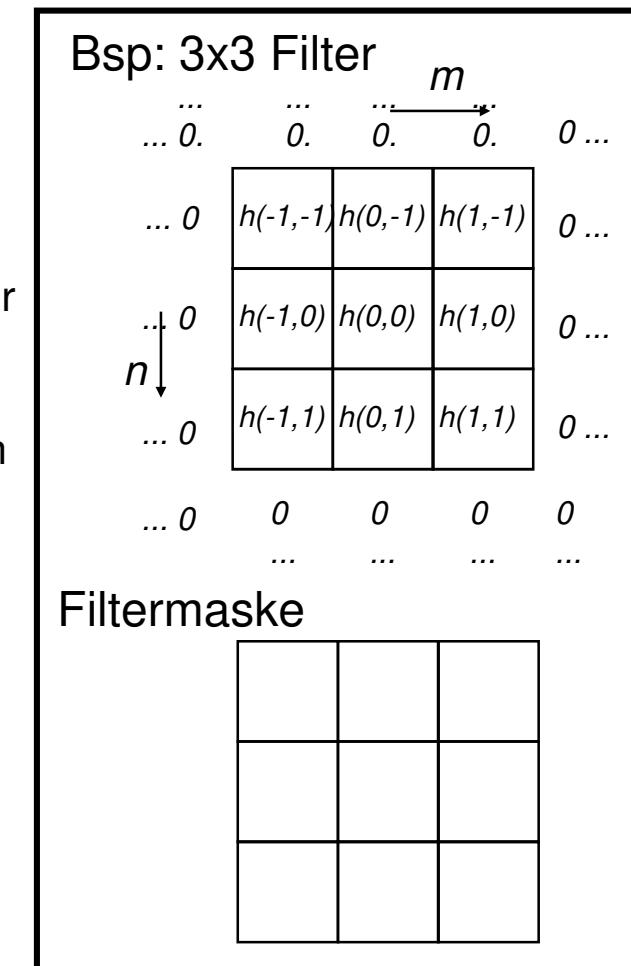
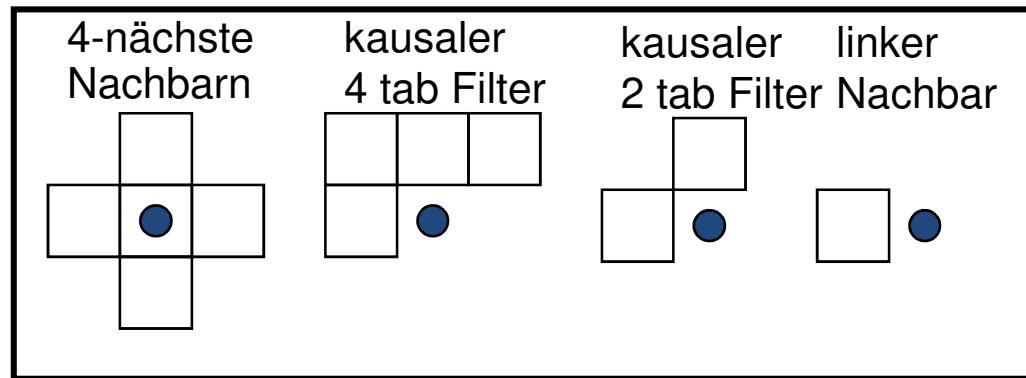


Winner, TUD

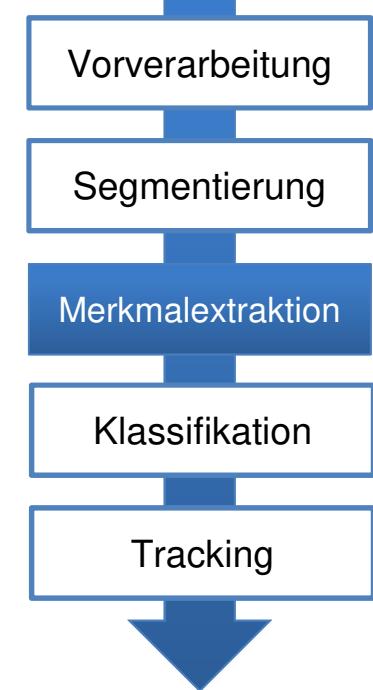
Merkmalsextraktion – Kantendetektion

Mehrdimensionale diskrete Faltung

- FIR-Filter (Finite Impulse Response):
Ein FIR-Filter ist ein lineares, verschiebungs-invariantes System, dessen Impulsantwort $h(m, n)$ nur endlich viele von 0 verschiedene Filterkoeffizienten hat.
Die Positionen der von 0 verschiedenen Koeffizienten bilden die Filtermaske.
- Weitere häufig verwendete Filtermasken:



Winner, TUD nach Stiller 2002



Merkmalsextraktion – Kantendetektion

- Sobel-Operator:

~~Sobel~~
▫ Sobel x: $G_x = S_x \cdot A = \begin{pmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{pmatrix} \cdot A$

und

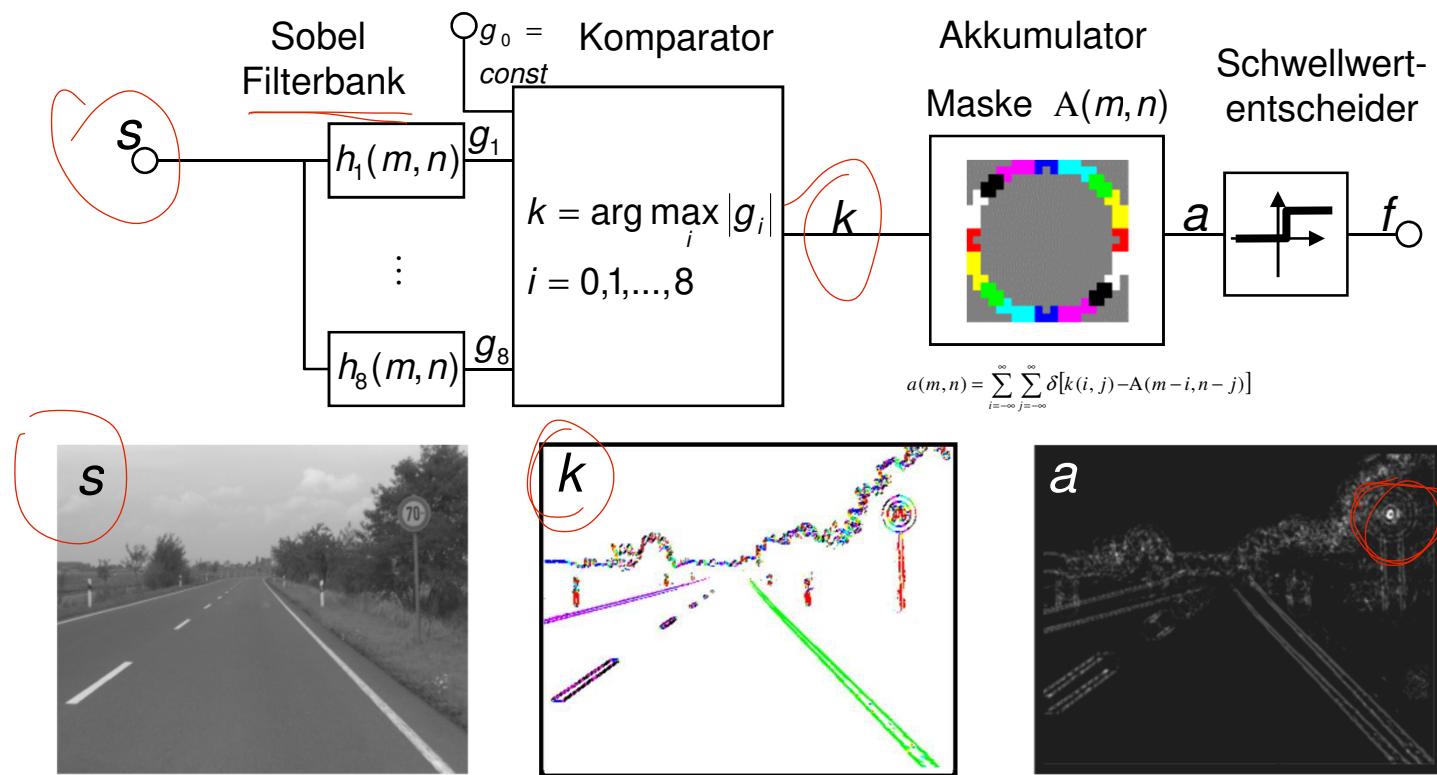
▫ Sobel y: $G_y = S_y \cdot A = \begin{pmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{pmatrix} \cdot A$

- Laplace-Operator:

~~Laplace~~
 $\begin{pmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{pmatrix}$ oder $\begin{pmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{pmatrix}$

Merkmalsextraktion

Suche nach Kreisen



Vorverarbeitung

Segmentierung

Merkmalsextraktion

Klassifikation

Tracking

Winner, TUD nach Stiller 2002

Zur Vorverarbeitung des Bildes werden Sobel-Operatoren eingesetzt, die die Änderung der Intensität des digitalen Bildes in je einer der Bilddimensionen bewerten. Durch die Kombination dieser beiden Einzelrichtungen können z. B. Steigungen oder Formen von Strukturen in der Größe eines bestimmten Winkels gefunden werden. Oft werden für die Identifikation von Strukturen bestimmte Muster gesucht. Für eine Fahrbahnmarkierungserkennung könnten dies die charakteristisch zum Fluchtpunkt verlaufenden Linien sein (oben sind diese farblich codiert), für eine automatische Erkennung von Verkehrszeichen zur Geschwindigkeitsbegrenzung die Kreisstruktur. Nach dem Vergleich mit einem Schwellwert kann für jeden Ort im Bild entschieden werden, ob der beobachtete Bereich zu der interessierenden Gruppe gehört.

Canny-Kantendetektor

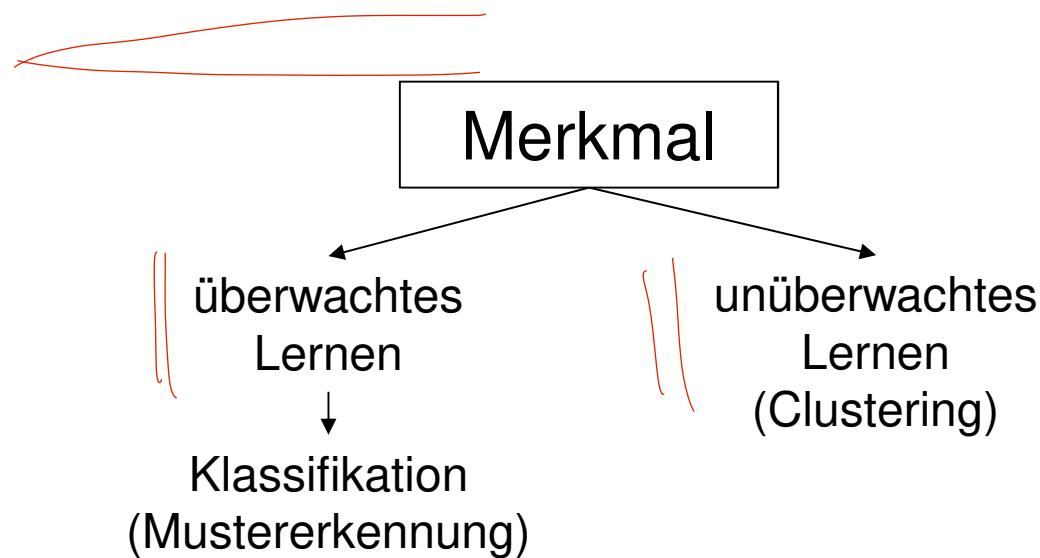
Der Canny-Algorithmus dient dem robusten Auffinden von Kanten in einem digitalen Bild, wie sie z.B. durch Strukturen wie Fahrzeuge oder Fahrbahnmarkierungen oder -begrenzungen auftreten. Der Algorithmus gliedert sich in verschiedene Stufen, die sequentiell durchlaufen werden. Ein Problem bei der Detektion bedeutet das Bildrauschen, da hierdurch lokal große Sprünge in den Helligkeiten zwischen zwei Pixeln auftreten können, die die Gefahr einer Fehldetektion als Kante beinhalten. Daher wird zunächst eine „Glättung“ des Bildes durch die Faltung mit einer Maske durchgeführt, beispielsweise einer Maske, die eine zweidimensionale Normalverteilung repräsentiert. Die Ausgestaltung dieser Maskenfunktion bestimmt die Robustheit des Verfahrens.

Der zweite Schritt besteht erneut aus einer Faltung mit einem sog. Sobel-Operator. Dabei wird diese Aktion zweimal durchgeführt einmal für jede Dimension des Bildes, es gibt also je einen Operator für die x- und y-Richtung im Bild. Jeder Operator filtert nun die Kanten bezogen auf seine jeweilige Richtung heraus, so dass sich für jede Dimension ein separates Zielbild ergibt. Zur Ermittlung der resultierenden Kantenstärken werden nun die Anstiege in den beiden Einzelrichtungen euklidisch addiert. Als letzter Schritt wird durch Definition eines Schwellwertes definiert, ab welchem Anstieg ein Pixel zu einer Kante zu zählen ist, anschließend liegt das Resultat wie im obigen Beispiel gezeigt, vor.

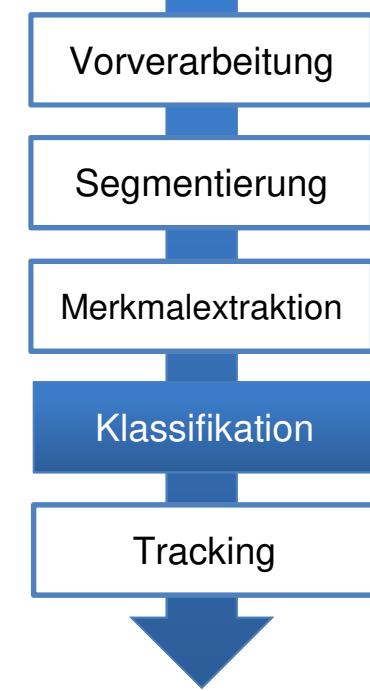
Harris-Eckendetektor

Eine Ecke ist dadurch gekennzeichnet, dass sich ausgehend vom Eckpunkt die Intensitäten in nahezu allen Richtungen der Bilddimension ändern. Es wird also ein Maß bestimmt, welches die „akkumulierte Änderung“ der Bildintensität für jeden Bildpunkt oder für kleine Gruppen von Bildpunkten bestimmt. Mit einer anschließenden Schwellwertfilterung können dann Ecken erkannt werden.

Klassifikation

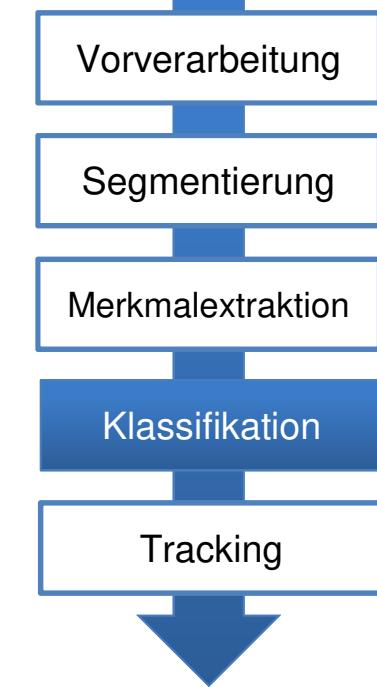
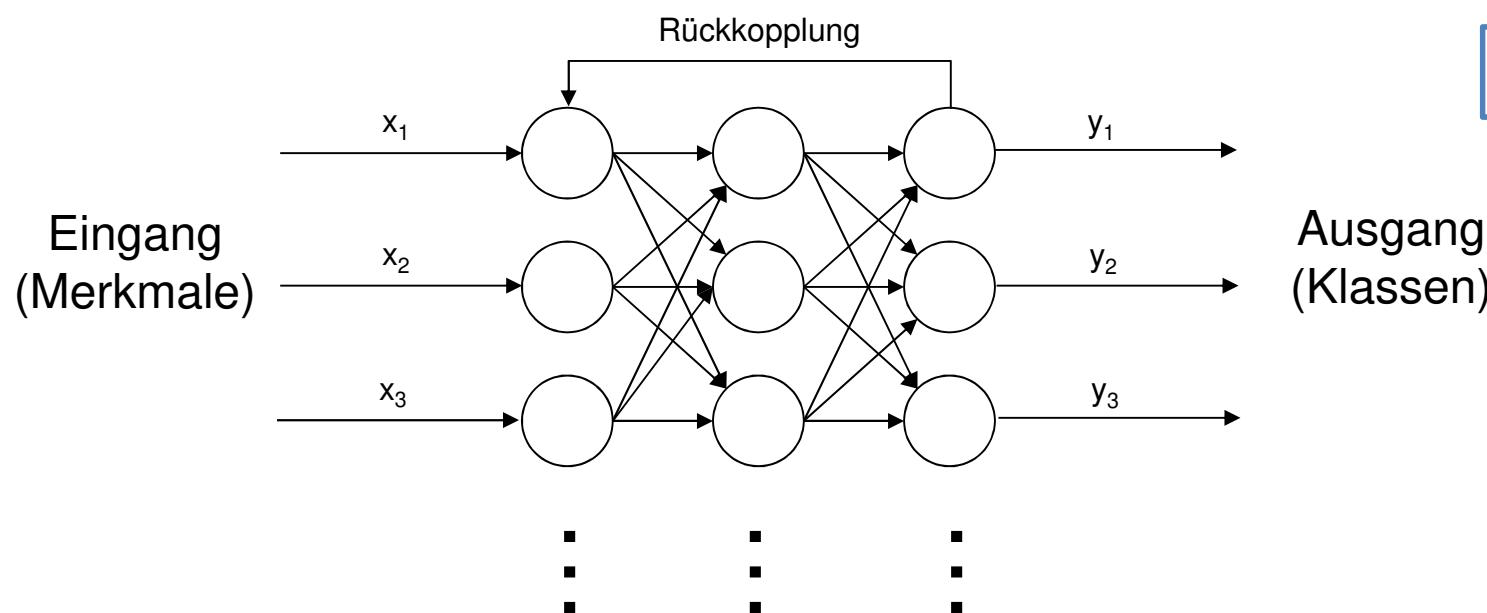


- **Überwachtes Lernen:** Zu jedem Trainingsbeispiel ist die Klassenzugehörigkeit bekannt
- **Unüberwachtes Lernen:** Klassen müssen über „natürliche Gruppen“ gefunden werden (Clustering)



Klassifikation

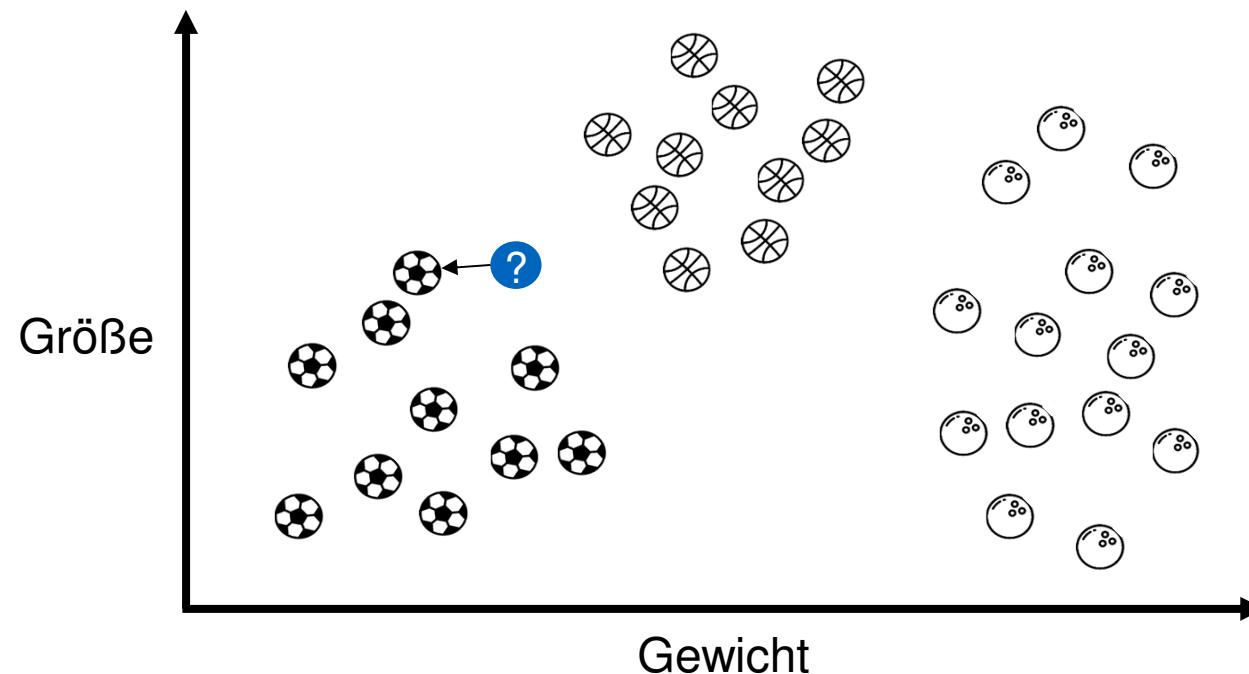
Nichtlineare Klassifikation mit Neuronalen Netzen



Klassifikation

Nearest Neighbors

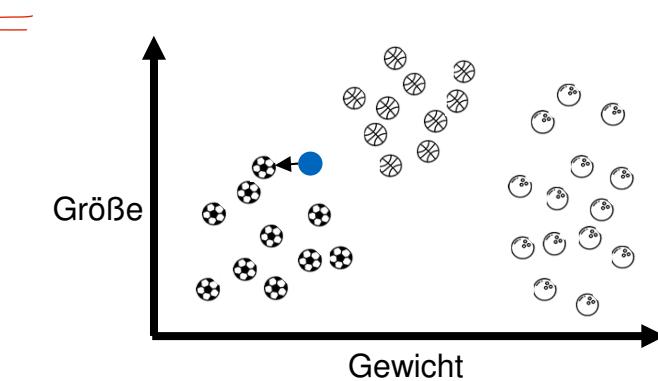
- Klassifikation von Objekten anhand ihres nächstgelegenen Nachbarn
- Keine Trainings- und Testphase → einfache Nutzung, aber hoher Speicher- und Zeitbedarf bei großen Datenmengen



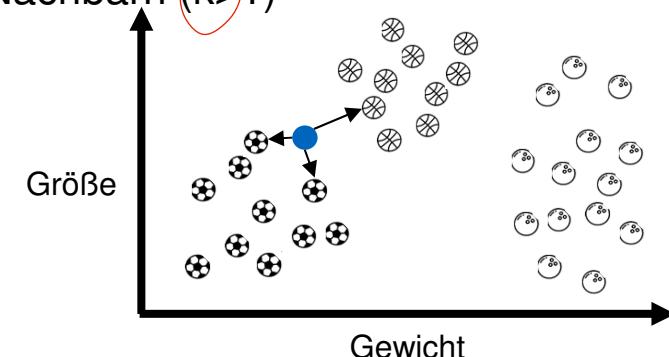
Klassifikation

Nearest Neighbors (NN): Varianten

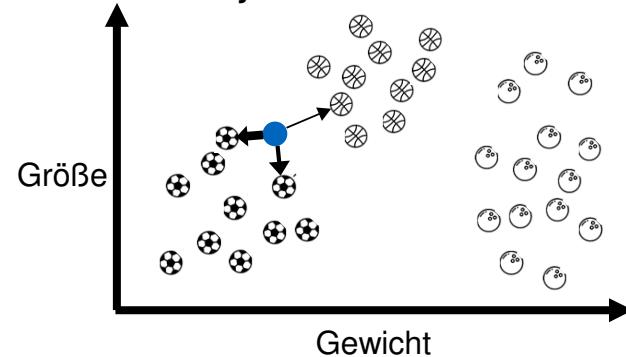
NN: Betrachtung des nächsten Nachbarn



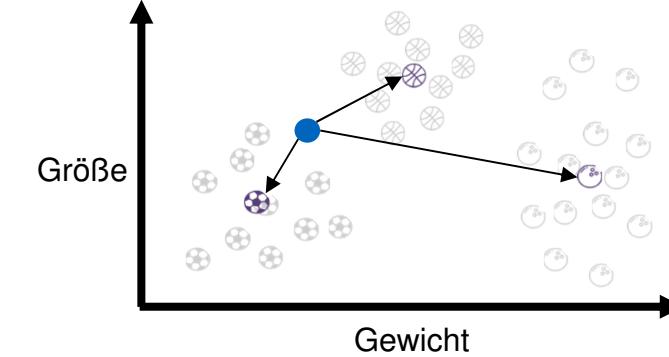
k-NN: Betrachtung der k nächsten Nachbarn ($k > 1$)



Weighted k-NN: k-NN, gewichtet nach Distanz zum Objekt



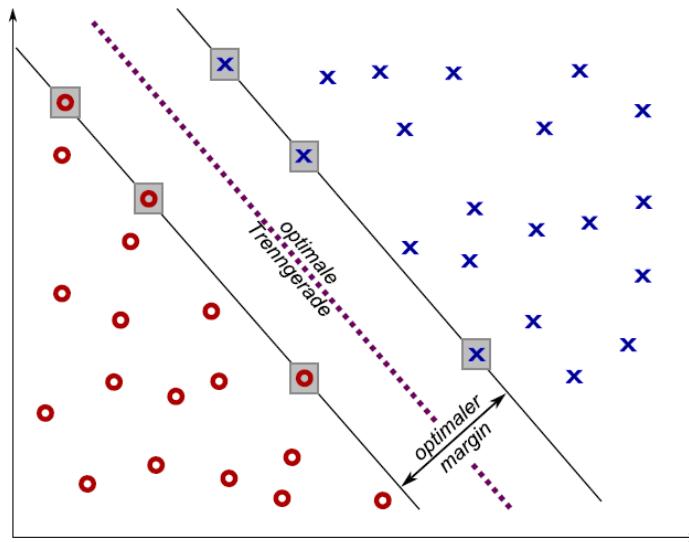
Mean-based NN: Klassifikation anhand der Distanz zur Mitte der Klassenmengen



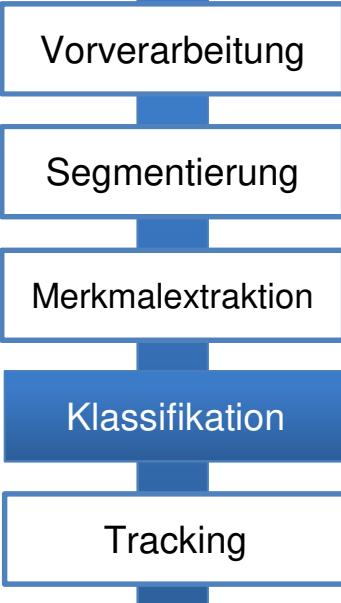
Klassifikation

Support Vector Machine (SVM)

- Grundprinzip: Klassentrennung durch Hyperebene im Merkmalsraum:



- Maximierung der margin (= Abstand der (zwei) Klassen von Trennebene)
- Vektoren mit minimalem Abstand = Support-Vektoren

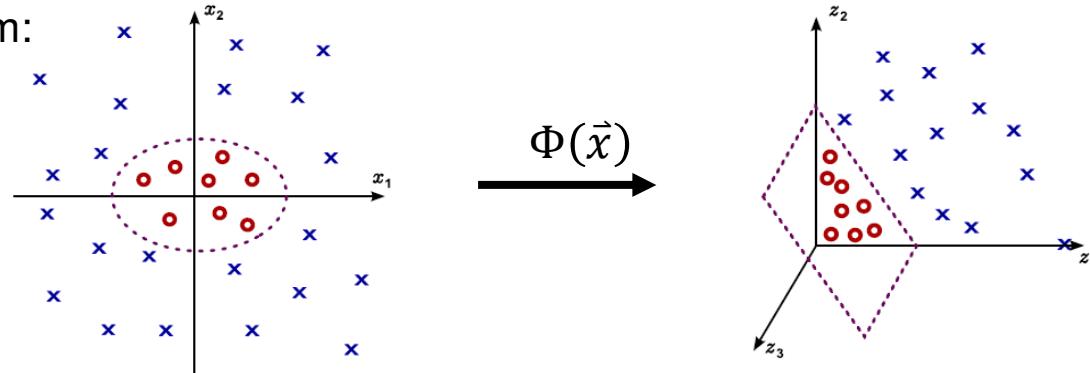


[Fink]

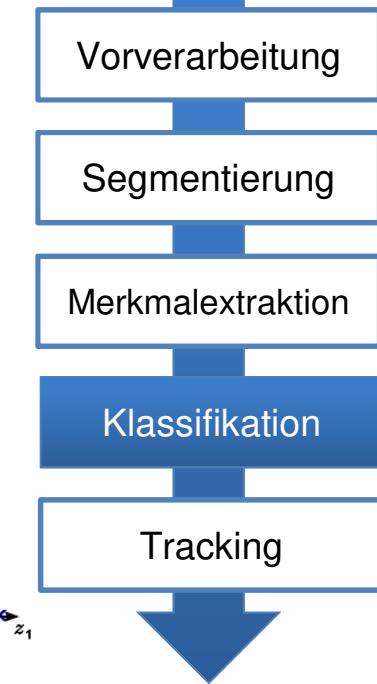
Klassifikation

Support Vector Machine (SVM)

- Idee: Sofern eine lineare Trennung der Klassen (Hyperebene) nicht möglich, transformiere Merkmalsrepräsentation in höherdimensionalen Raum:



- Vereinfachung durch Wahl eines *Kernels*
→ explizite Berechnung der hochdimensionalen Repräsentation vermieden!
- Eigenschaften:
 - + sehr leistungsfähiges Verfahren
 - + Kann auf Mehrklassenprobleme erweitert werden
 - Aufweichung des Prinzips in der Praxis erforderlich (*slack-Variable*)
 - Parameteroptimierung extrem aufwendig



[Fink]

当前图像

搜索线的位置

边缘点检测

确定道路模型

Aktuelles Bild



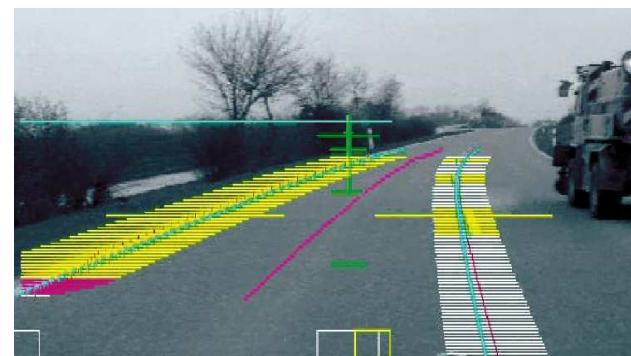
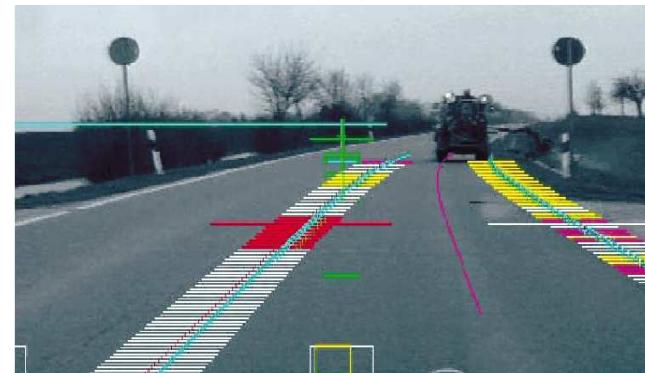
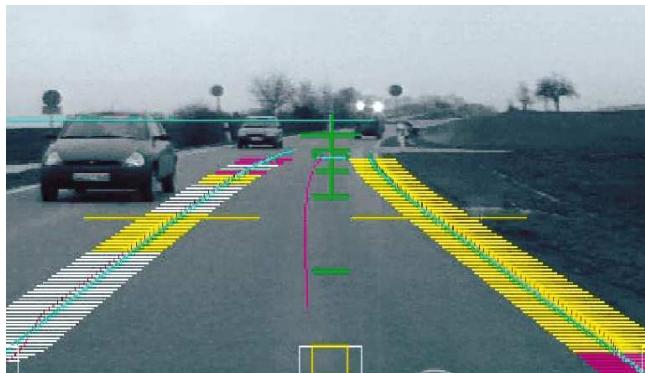
Platzierung von
Suchlinien



Detektion von
Kantenpunkten



Festlegung vom
Modell des
Fahrbahnverlaufs



Winner, TUD nach [DaimlerChrysler 2001]

Bei der Befestigung einer Kamera hinter einer Windschutzscheibe befinden sich Fahrstreifenmarkierungen normalerweise nicht an beliebigen Stellen im Bild, sondern mit hoher Wahrscheinlichkeit innerhalb bestimmter Bereiche entlang des Fahrbahnrandes. Um diese Bereiche werden daher Suchbereiche gelegt, auf deren Grundlage die Fahrbahnmarkierungen erkannt werden können. Als Ergebnis liegt ein mathematisches Modell des Fahrbahnverlaufes vor.

Eine sehr effektive Methode zur Eingrenzung des Rechenaufwandes ist die selektive Bildverarbeitung, die sich nur auf die Stellen im Bild konzentriert, die die erwartete Information enthalten können. So werden bei der Fahrstreifenerkennung nur in dem Bereich die Kanten untersucht, in dem der Fahrstreifen vermutet wird.

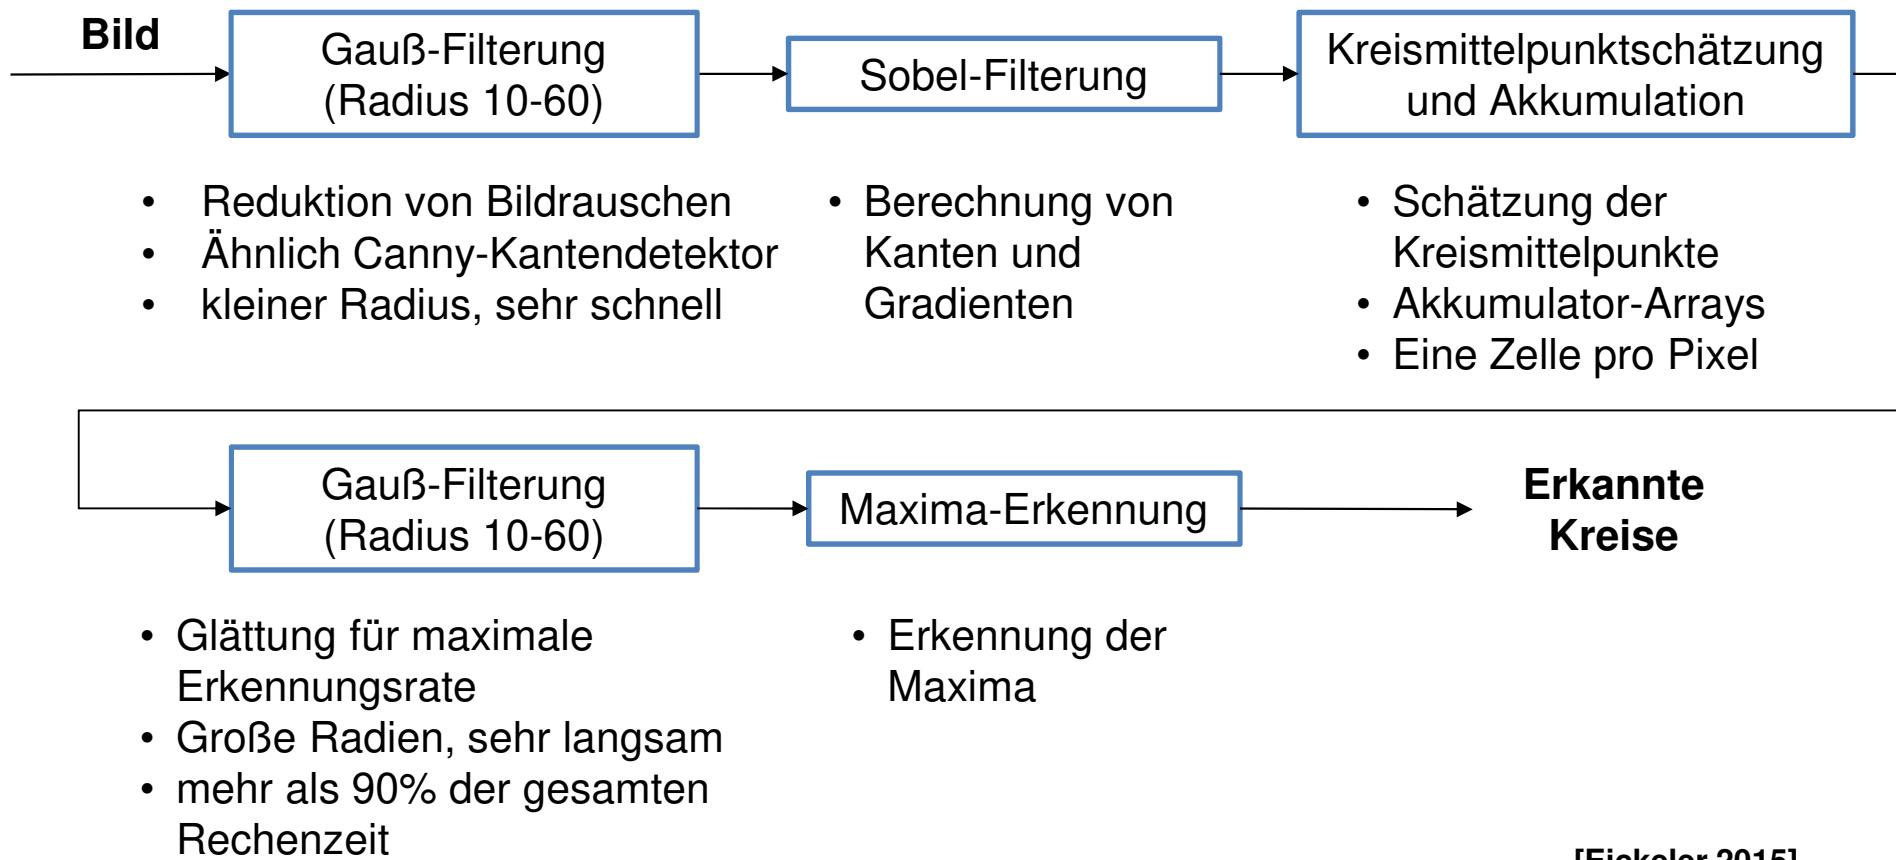
Die Bildfolge zeigt die Arbeitsweise der Fahrstreifenerkennung. Die Bildauswertung orientiert sich an den Fahrbahnmarkierungen. Zunächst werden Mittelstreifen und rechter Fahrbahnrand detektiert. Beim Überholen wird die Markierung des linken Seitenrands erfasst.

Anwendungsbeispiel: Verkehrzeichenerkennung



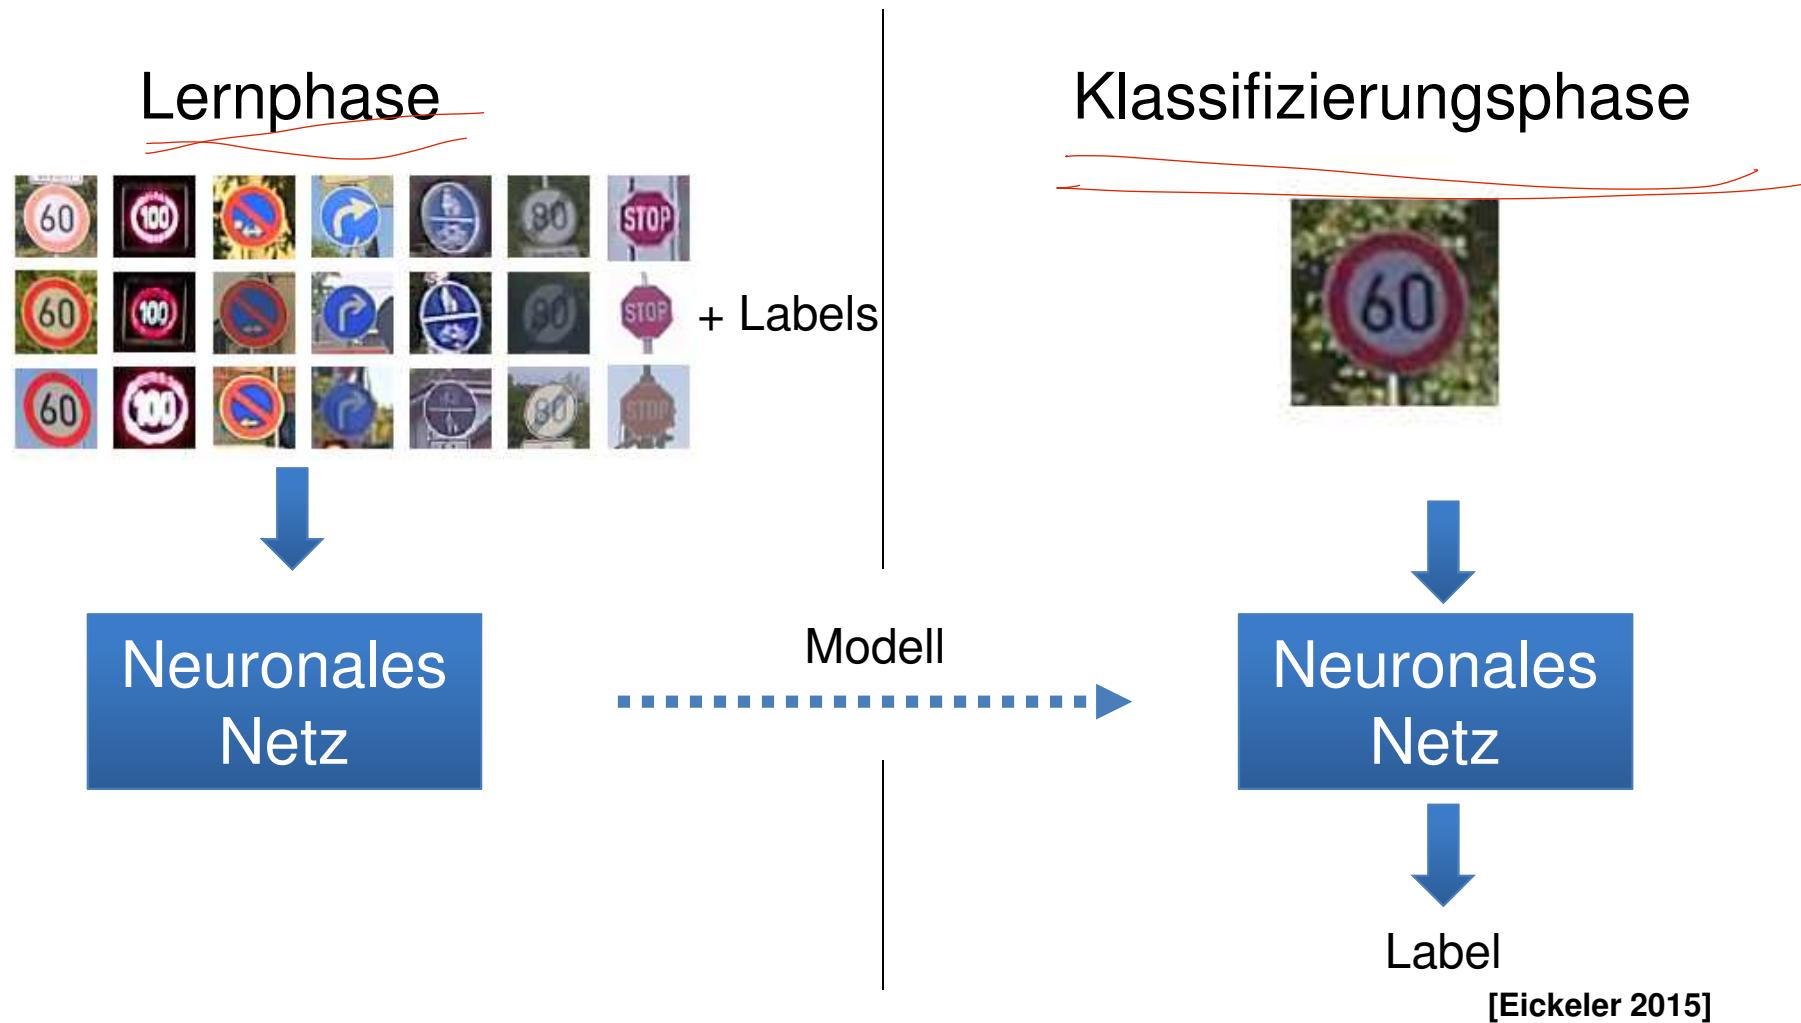
[Blauth 2012]

Erkennung von runden Verkehrszeichen



[Eickeler 2015]

Klassifikation durch neuronale Netze



Erkennung von dreieckigen Verkehrszeichen

Detektionsleistung



Genauigkeit (Accuracy)	Trefferquote (Recall)	Erkennungsrate (Precision)
98,9%	95,5%	98,3%

$$\frac{TN + TP}{TN + TP + FP + FN} \quad \frac{TP}{FN + TP} \quad \frac{TP}{TP + FP}$$

Legende:

T – True

F – False

P – Positive

N – Negative

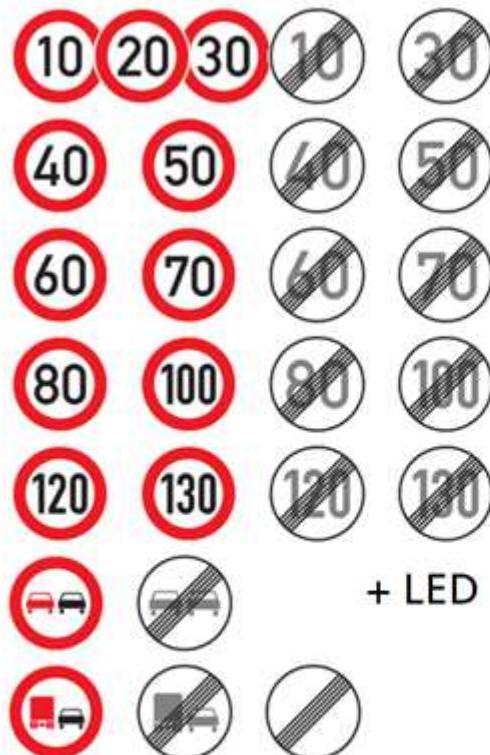


Garbage

[Eickeler 2015]

Erkennung von runden Verkehrszeichen

Detektionsleistung



	Genaug-keit (Accuracy)	Treffer-quote (Recall)	Erkennungs-rate (Precision)
Tempolimits	98,8%	99,7%	98,7%
Alle	98,6%	99,2%	98,4%



Garbage



[Eickeler 2015]

1) Genauigkeit (Accuracy)

Wie groß ist der Anteil an korrekten Vorhersagen?

Die Genauigkeit "accuracy" war (Anzahl an True Negatives + True Positives) geteilt durch "Anzahl an test cases"

$$\frac{TN + TP}{TN + TP + FP + FN}$$

2) Trefferquote (Recall)

Welchen Anteil an positiven Fällen sind detektiert worden?

Die Trefferquote "recall" war "Anzahl an True Positives" geteilt durch "Anzahl an positive cases → False Negatives + True Positives"

$$\frac{TP}{FN + TP}$$

3) Erkennungsrate (Precision)

Welcher Anteil an positiven Vorhersagen war korrekt?

Die Erkennungsrate "precision" war "Anzahl der True Positives" geteilt durch "Anzahl an predicted positives □ True Positives + False Positives"

$$\frac{TP}{TP + FP}$$

Sensorik / Wahrnehmung II

Dr.-Ing. Frank Diermeyer
(Andreas Schimpe, M.Sc.)

Agenda

3 Sensorik / Wahrnehmung II

3.1 Detektion mit LiDAR und RADAR

3.2 Maschinelles Sehen

 3.2.1 Kameramodell

 3.2.2 Diskretisierung

 3.2.3 Stereoskopie

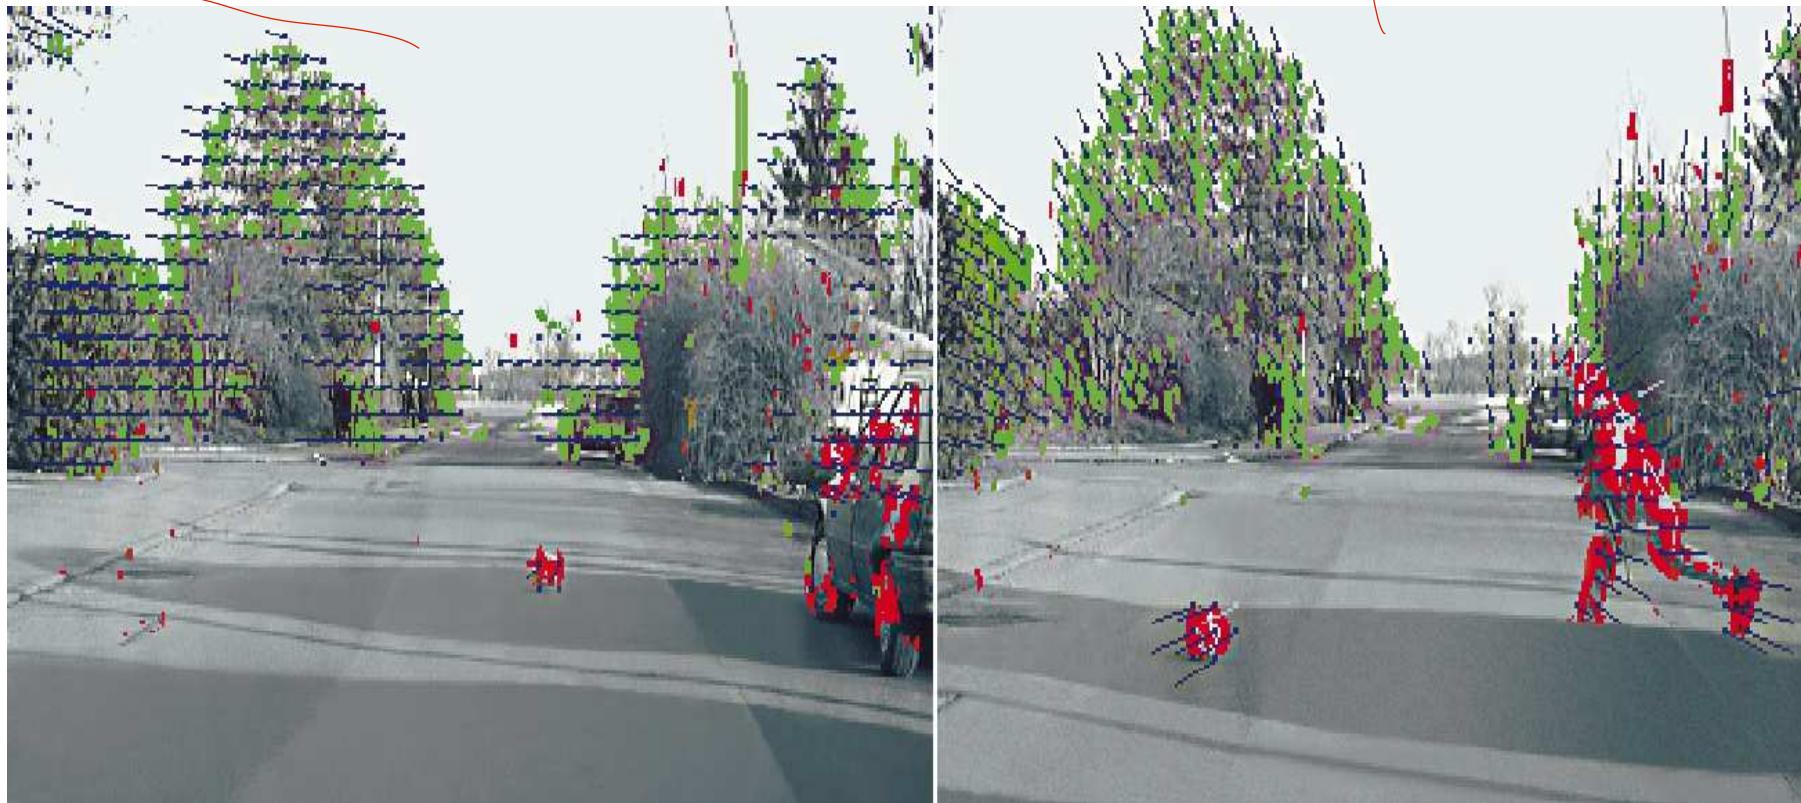
 3.2.4 Bildbasierte Mustererkennung

 3.2.5 Bewegungsdetektion



Bewegungsdetektion

Optischer Fluss zur Fußgängererkennung



Winner, TUD nach [DaimlerChrysler 2001]

Umgebungserfassung mit optischem Fluss

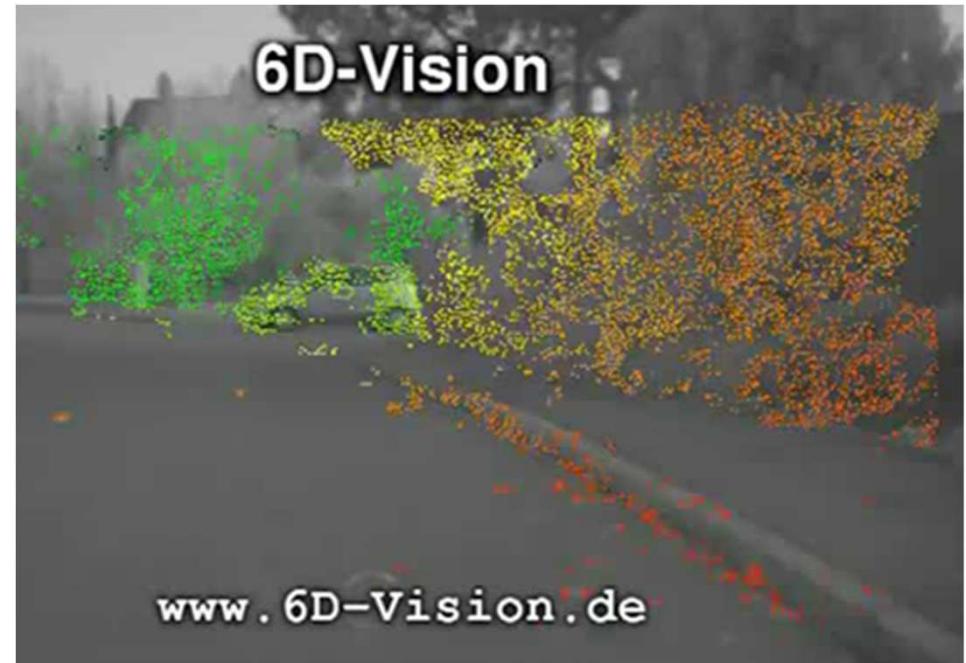
Arbeitet auf Bildfolgen. Optischer Fluss basiert auf der Annahme, dass Intensitätsänderungen im Bild nur durch Bewegung erzeugt werden. Ergebnis ist ein zweidimensionales Feld von Geschwindigkeitsvektoren, im Bild die roten Pfeile.

Ebene Strukturen (z.B. Fahrbahn) erzeugen Geschwindigkeitsvektoren, die die Eigenbewegung reflektieren. Stehende Objekte weichen von den prädizierten Bewegungsvektoren der Ebene ab und lassen sich so erkennen.

Optischer Fluss zur Fußgängererkennung

Die unterschiedlichen Erkennungsmodule zum technischen Sehen konzentrieren sich auf bestimmte Merkmale im Bild. Die beiden Standbilder aus einer Videosequenz zeigen sowohl die Sicht des menschlichen Auges auf diese gefährliche Situation als auch – durch Farüberlagerung –, auf welche Objekte die Module ansprechen.

Fusion von optischem Fluss und Stereo-Vision (6D)



- Entwickelt durch Daimler Forschung
- 6 Dimensionen:
 - 3D-Bilder durch Stereokameras
 - dreidimensionale Bestimmung des optischen Flusses innerhalb dieser Bilder
 - Bestimmung von Entfernungen

Winner, TUD nach www.6d-vision.de

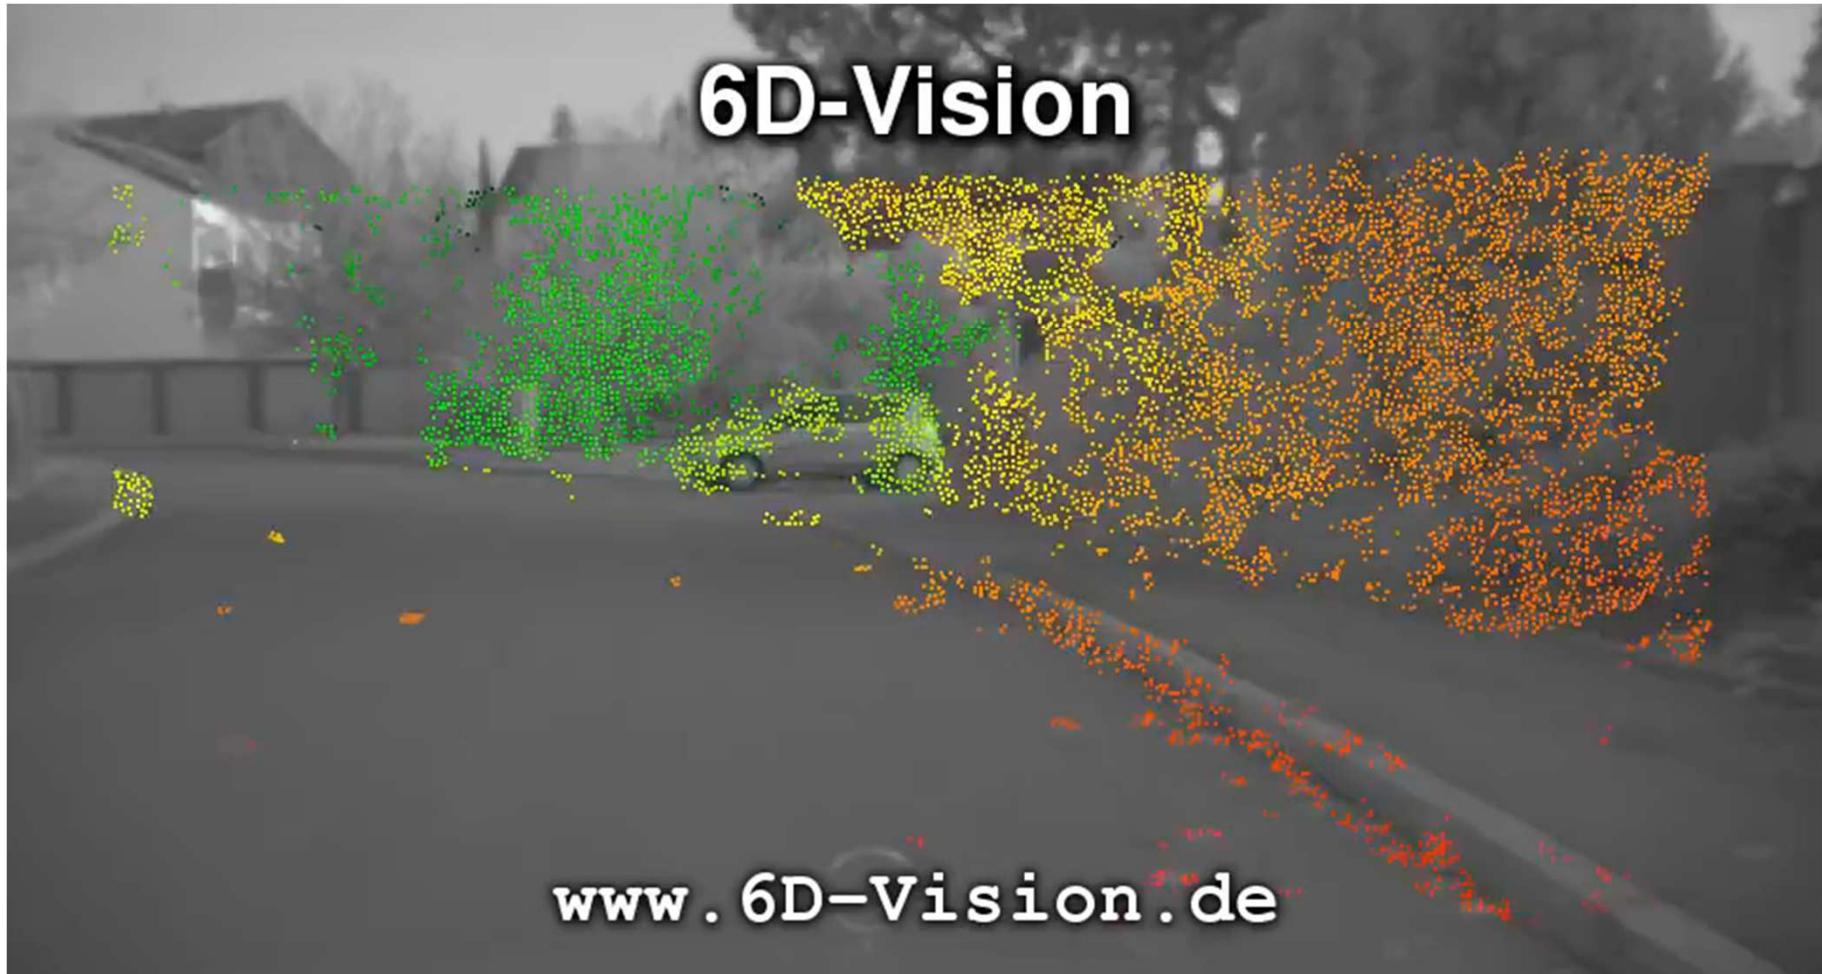
6D-Vision ist ein von den Daimler-Forschern Dr. Uwe Franke, Dr. Stefan Gehrig und Dr. Clemens Rabe entwickeltes Verfahren der Bildverarbeitung, mit Hilfe dessen Autos in Bruchteilen einer Sekunde mögliche Kollisionsgefahren erkennen können. Die Besonderheit ist, dass sogar bewegte Objekte wie z.B. andere Fahrzeuge, Fahrradfahrer oder Fußgänger detektiert werden können, noch bevor sie sich im Fahrkorridor befinden. Die beiden Bilder zeigen zwei kritische Situationen, für die das Verfahren entwickelt worden ist.

6D-Vision verwendet dazu ein Stereokamerasystem, um wie der Mensch räumlich sehen zu können. Durch eine zeitliche Analyse der Bildfolge, gewissermaßen einem mehrfachen Hinschauen, können zusätzlich Bewegungsrichtung und Geschwindigkeit ermittelt werden. Diese Kenntnis erlaubt eine Prognose der zukünftigen Position. Die Pfeile in den Bildern zeigen, wo die gefährdeten Personen in 0,5 Sekunden sein werden.

„6D-Vision verwendet das Prinzip des Stereosehens, um die 3D-Position einzelner Bildpunkte zu ermitteln. Um die Geschwindigkeit zu messen, werden diese Bildpunkte anschließend von Bild zu Bild verfolgt, was eine klassische Aufgabe im Bereich der Computer Vision ist (vgl. Optischer Fluss). Da in jedem Bild wieder die 3D-Position ermittelt wird, kann unter der Annahme, dass sich Punkte eines Objektes geradlinig bewegen, durch geeignete Filterung der 3D-Geschwindigkeitsvektor ermittelt werden.[...] 3D-Position und 3D-Bewegung ergeben zusammen die sechs Dimensionen des Verfahrens.“

Winner, TUD nach www.6d-vision.de

6D-Vision



Stixel-Welt



www.6d-vision.de

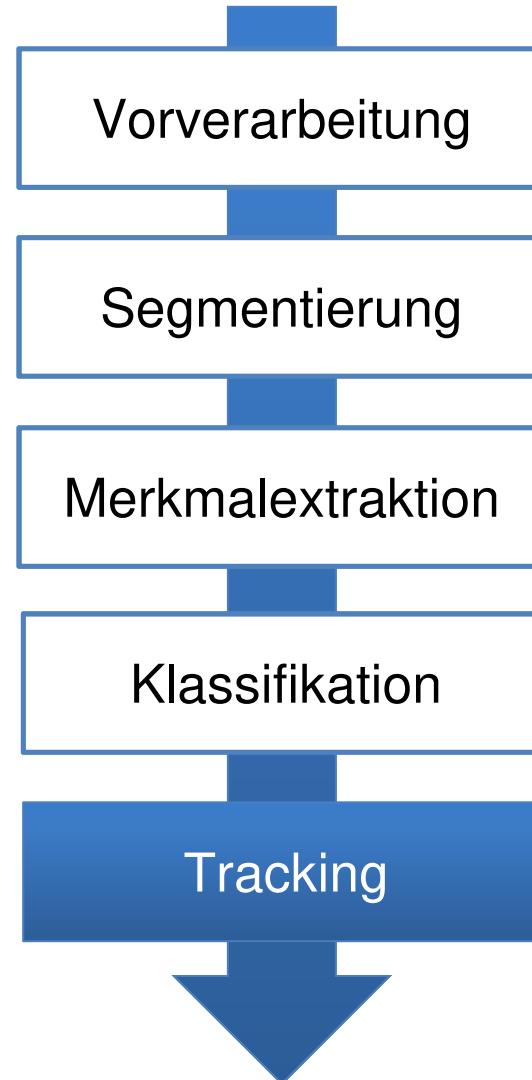
Das Prinzip der 6D-Vision, 3D-Punkte von Bild zu Bild zu tracken und so Position und Geschwindigkeit zu bestimmen, ist nicht auf einzelne Punkte beschränkt. Es kann auch auf Gruppen von Punkten, sogenannte Superpixel, angewendet werden.

Hier werden rechteckige Elemente, sogenannte Stixel, als Superpixel verwendet, um die aufgenommene Verkehrsszene kompakt und ohne Verlust relevanter Informationen zu modellieren, bevor der eigentliche 6D-Vision-Prozess gestartet wird. Dank eines leistungsfähigen Optimierungsalgorithmus passen sich diese Stixel sehr gut an die Objekte in der Umgebung an. Das Bild zeigt beispielhaft die Darstellung einer innerstädtischen Szenerie, wobei die Farben die Entfernung kodieren (rot bedeutet nah, grün weiter entfernt). Nachfolgende Schritte wie Hinderniserkennung, Berechnung verfügbaren Straßenraumes oder Aufmerksamkeitsüberwachung müssen pro Bild nicht eine halbe Million 3D-Punkte analysieren, sondern lediglich 500-1000 Stixel. Werden die Stixel über mehere Bilder hinweg verfolgt, ermöglicht das Prinzip der 6D-Vision eine Abschätzung ihrer Bewegung. Das Video zeigt die Situation an einer Ampel, wobei die Entfernung wiederum farbkodiert ist und die Pfeile am Boden die in 500 ms erwartete Position der Stixel anzeigen. Da durch die Filterung während des 6D-Vision-Prozesses alle Bildpunkte in ihrer Gesamtheit betrachtet werden, lassen sich genauere Messungen von Position und Geschwindigkeit erzielen als mit isolierten Punkten.

Anwendungsbeispiel von 6D-Vision (Ausweichassistentensystem)



Nächster Termin



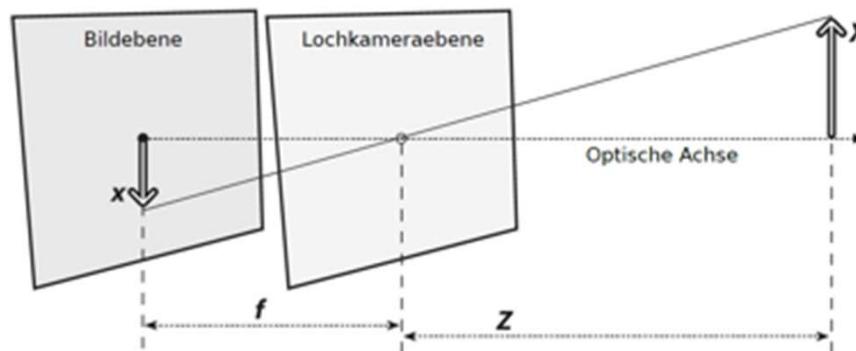
Zusammenfassung der Leitfragen

- Wie ist das Vorgehen bei der Mustererkennung und wie kann es angewendet werden?



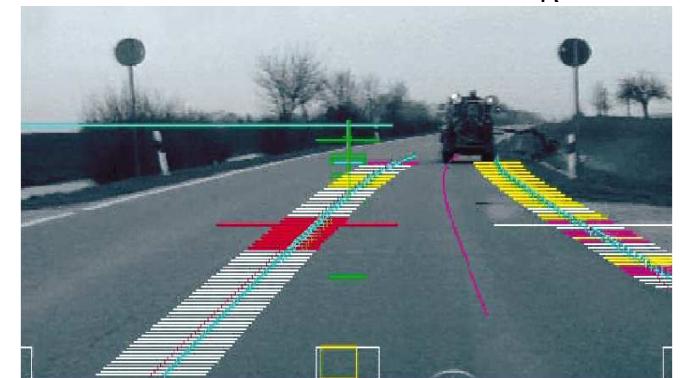
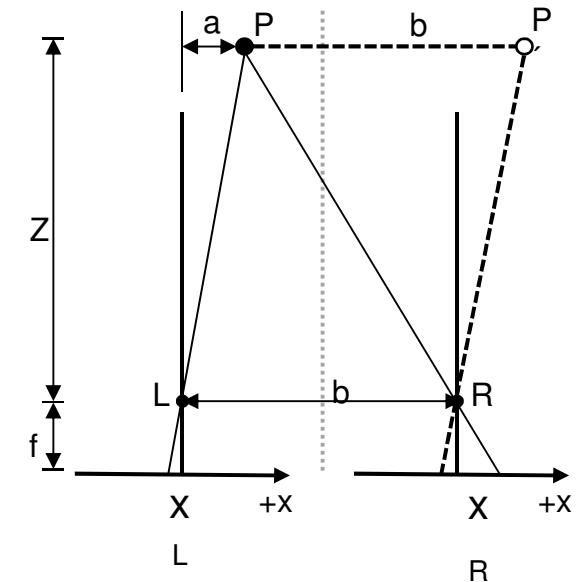
- Wie funktioniert ein einfaches Kameramodell?

- Lochkameramodell: kleine Blendenöffnung → scharfe Abbildung – in Praxis mit Abbildungsoptik



Zusammenfassung der Leitfragen

- Wie funktioniert Stereoskopie?
 - Simultane Aufnahme von zwei Bildern
 - Vergleich und Zuordnung von Feature in beiden Bildern
 - Triangulation
- Wie funktionieren verschiedene Verfahren zur Kantendetektion und wie können sie angewendet werden?
 - Mehrdimensionale diskrete Faltung
 - FIR-Filter, Sobel- u. Laplace-Operatoren
 - Canny-Kantendetektor
- Welche Ansätze zur Klassifikation gibt es?
 - Neuronale Netze
 - Nearest Neighbors
 - Support Vector Machine



Quellenverzeichnis

- Blauth, Marco (2012): Detektion und Klassifikation von Verkehrszeichen in Bildsequenzen basierend auf Farb- und Formmerkmalen. Bachelorarbeit. Fachhochschule Kaiserslautern, Kaiserslautern. Fachbereich Angewandte Ingenieurwissenschaften.
- Buddendick, H.; Eibert, T. F. (2010): Acceleration of Ray-Based Radar Cross Section Predictions Using Monostatic-Bistatic Equivalence. In: *IEEE Trans. Antennas Propagat.* 58 (2), S. 531–539. DOI: 10.1109/TAP.2009.2037692.
- DaimlerChrysler, A. G.: HighTech Report 2001. In: *Online im Internet unter URL: http://www.daimlerchrysler.com/research/research\g.htm* (04.01. 2002).
- Duda, Richard O.; Hart, Peter E.; Stork, David G. (2012): Pattern classification: John Wiley & Sons.
- Eickeler, Stefan (2015): Next Steps for Traffic Sign Recognition Systems. Institut für intelligente Analyse und Informationssysteme (Fraunhofer IAIS), 2015.
- Fink, Gernot A. (2007): Mustererkennung. Prinzipien, Methoden, Anwendungen. Technische Universität Dortmund, Fakultät für Informatik / Institut für Roboterforschung. Dortmund, 28.11.2007.
- Herrmann, Martin, Gaschler, Philipp: Wie findet man interessante Punkte?
- Hosseini, Amin; Diewald, Fabian; Klappstein, Jens; Dickmann, Jürgen; Neumann, Heiko: Modification of the landweber method based on the conjugate gradient method to restore automotive radar images. In: 19th International Conference on Systems, Signals and Image Processing (IWSSIP), 2012. 11 - 13 April 2012, Vienna, Austria. Institute of Electrical and Electronics Engineers; International Conference on Systems, Signals and Image Processing; IWSSIP. Piscataway, NJ: IEEE, S. 544–547.
- Kürbig, Jens; Sauter, Martina (2005): Bildsegmentierung: Übersicht.
- Mukhtar, Amir; Xia, Likun; Tang, Tong Boon (2015): Vehicle Detection Techniques for Collision Avoidance Systems. A Review. In: *IEEE Trans. Intell. Transport. Syst.* 16 (5), S. 2318–2338. DOI: 10.1109/TITS.2015.2409109.
- Pietzsch, Sylvia (2015): Modellgestützte Sensordatenfusion von Laserscanner und Radar zur Erfassung komplexer Fahrzeugumgebungen. München, Technische Universität München, Diss., 2015.
- Stöckler, Joachim: Mathematische Methoden der Bildverarbeitung. Technische Universität Dortmund.
- Strumillo, Paweł (2005): Segmentation. Uniwersytet Łódzki. Łódź, 2005.
- Winner, Hermann; Hakuli, Stephan; Wolf, Gabriele (Hg.) (2009): Handbuch Fahrerassistenzsysteme. Grundlagen, Komponenten und Systeme für aktive Sicherheit und Komfort ; mit 45 Tabellen. 1. Aufl. Wiesbaden: Vieweg+Teubner Verlag / GWV Fachverlage GmbH Wiesbaden (PRAXIS | ATZ/MTZ-Fachbuch).